



Módulo III | Clase 5

Análisis exploratorio de datos local con DuckDB





¿Ponemos a grabar el
taller?

Primera pre-entrega

¡En esta clase, deberán entregar los desafíos resueltos en la notebook 5 y 7. Los mismos serán subidos como repositorio a su cuenta de Github.

Presentarán lo trabajado entregando el link al de Github en el foro del aula virtual



¿Qué vamos a ver hoy?



- ¿Qué es el análisis exploratorio de datos?
 - Importancia del análisis exploratorio de datos
 - ¿Qué debo buscar en un AED?
- Exploración de datos parte 1:
Descripción de datos
Visualización de datos



¿Qué es el análisis exploratorio?

Análisis exploratorio de datos local con DuckDB



El análisis exploratorio de datos tiene por objetivo **identificar** las principales **características** de un conjunto de datos mediante un número reducido de gráficos y/o números



¿Por qué es importante?

Nos ayuda a **organizar la información** que nos provee los datos a fin de **detectar patrones** presentes así como también datos que se apartan de manera sobresaliente del modelo subyacente.

Debe ser el **primer paso** en cualquier modelado



¿Qué buscamos en el análisis exploratorio?

Buscamos...



Análisis

Individual de cada variable

De las relaciones subyacente entre ellas

Mediante

Métodos gráficos

Medidas resumen

¿Qué buscamos?

- **¿Cuántos features tengo (Columnas)? ¿Nombre?**
Feature o atributo: Propiedad o característica individual y medible de un fenómeno observado.
- **¿Cuántas observaciones tengo (filas)?**
- **¿Cada fila contiene sólo atributos de una observación?**



¿Qué buscamos?

¿Qué tipos de variables tengo?

Categóricas o cualitativas: ¿Están representadas por números o strings?

Cuantitativas discretas

Cuantitativas continuas

El tipo de datos determina el método de análisis apropiado y específico



¿Qué buscamos?

¿Qué tipos de valores faltantes?

Faltantes random

Faltantes NO random


¿Hay valores erróneos?



Distribución de las variables continuas


A

Gráficos: A través de histogramas, distplots o boxplots.




B

Numéricos: Media aritmética, Mediana, rango y quartiles, medidas de dispersión



Distribución de las variables continuas

- Permite ver si la distribución de mi variable es normal, logarítmica, sesgada a la izquierda o a la derecha, etc.
- Algunos algoritmos asumen la distribución de nuestra variable target es normal
- Para poder filtrar outliers debo saber la distribución de una variable




Frecuencia de cada categoría

A

Gráficos: Countplots o barras

B

Tablas de frecuencias




Frecuencia de cada categoría

- Permite ver si cada nivel en una variable categórica está representada o si hay sobrerrepresentación de un nivel
- Los algoritmos de clasificación requieren que el dataset no tenga desbalance de clases.

Comparar varios conjuntos de datos


A

Gráficos: A través de boxplots, gráfico de barras.



B

Numéricos: Comparar la media aritmética, mediana, rango y cuartiles, medidas de dispersión



Evaluar relaciones: Correlación

A

Gráficos: Scatterplots, pairplots.

B

Numéricos: Análisis de correlación

```
correlacion = df.corr(method='pearson')
```

	nombre	saldo	categoria
nombre	1.000000	0.084695	-0.028462
saldo	0.084695	1.000000	-0.023454
categoria	-0.028462	-0.023454	1.000000




Evaluar relaciones: Correlación

- Permite identificar la relación entre las variables independientes y la variable target.
- Permite establecer correlaciones entre las variables independientes
- Evitar COLINEALIDAD




Evaluar relaciones: Correlación

Heatmap



Scatterplot





Descanso

Nos vemos en 10 minutos



Repasamos en Kahoot



Juguemos un rato

Respondemos algunas preguntas en Kahoot





¿Alguna consulta?

DESAFÍO 5

Para la siguiente clase:



- Elegir un tema y un Dataset para el trabajo final. Publicar el mismo en el foro del aula virtual
- Además, describir cuál podría ser el objetivo de su proyecto

Pueden reconfigurar los grupos de trabajo o volver a armarlos. En tal caso, cuando entreguen el desafío, deberán colocar el nombre de las participantes e informar a la tutora





Repasamos

Análisis exploratorio de datos local con DuckDB



El análisis exploratorio de datos tiene por objetivo **identificar** las principales **características** de un conjunto de datos mediante un número reducido de gráficos y/o números



Buscamos...



Análisis

¿Cuántos features tengo (Columnas)? ¿Nombre?
¿Cuántas observaciones tengo (filas)? ¿Cada fila
contiene sólo atributos de una observación?

• ¿Qué tipo de variables tengo?

¿Hay valores faltantes? ¿Hay valores erróneos?



Sección práctica:

Aprendemos cómo describir datos con la primera parte de la Notebook 8

En la sala general

Describiendo datos

Trabajamos con la primera parte de la Notebook 8

Demostraremos cómo describir los datos
con Pandas.





Descanso

Nos vemos en 10 minutos



Herramientas para visualización de Datos

Matplotlib



Matplotlib es una librería *open source* desarrollada por John Hunter en **2002** con el fin de imitar las funcionalidades de creación gráfica de Matlab en Python.




¿Por qué Matplotlib?

Matplotlib ofrece una **amplia variedad de gráficos** básicos y avanzados. Brinda métodos para poder modificar y añadir elementos a los gráficos de manera muy sencilla. Ofrece tutoriales para aprender como hacer los distintos plots.




Seaborn

Seaborn es una librería para representación estadística desarrollada sobre Matplotlib, pero que está diseñada para facilitar tanto el trabajo con los datos como la **personalización de los gráficos**.



¿Por qué Seaborn?

Seaborn representa fácilmente distribuciones de datos o agregaciones sin tener que darle formatos complejos al DataFrame. Su galería de gráficos es más amplia que Matplotlib y está más focalizada en la estética, por lo que permite una personalización de gráficos es mayor.





Sección práctica:

Aprendemos cómo visualizar datos con la segunda parte
de la Notebook 8

En la sala general

Visualización de datos

Trabajamos con la segunda parte de la Notebook 8

Demostraremos cómo visualizar los datos
con Pandas.

DESAFÍO 6



Para la siguiente clase:

Practicar cómo describir y visualizar datos en Pandas. Se sugiere ir avanzando con sus propios Dataset elegidos en grupo, de modo de llevar al proyecto propio lo visto en clase.





¿Alguna consulta?

FUNDACIÓN
YPF

¡Muchas Gracias!

En la próxima clase veremos:
`Exploracion_datos_parte2`

