



Módulo III | Clase 6

Análisis exploratorio: Valores faltantes, Outliers e IA





¿Ponemos a grabar el
taller?

¿Qué vamos a ver hoy?



- Valores faltantes
- Filtrado de Outliers

- Práctica: explorando los datos



VALORES FALTANTES

Valores Faltantes

Los Imputación asistida: usando copilotos de IA para generar códigos y proponer estrategias coherentes con el negocio.
son aquellos que para una variable determinada no están presentes en algunas filas o patrones. Suele ser común encontrarlos en datasets del mundo real y representan un desafío para los data scientists.

Tipos de valores faltantes

- **MCAR** (missing completely at random) la probabilidad para todas las instancias es la misma y no depende de las medidas de otras variables. (Encuesta)
- **MAR** (missing at random): depende de la información observada. (Volumen de precipitaciones)
- **MNAR** (missing not at random) está relacionada con los valores perdidos. (Salario elevado)

Valores faltantes

- Imputación asistida: usando copilotos de IA para generar códigos y proponer estrategias coherentes con el negocio.
- Observar no solo la cantidad de datos faltantes sino también su patrón.



Estrategias

A Eliminar los valores


- Si la recogida de datos no se ha realizado de forma aleatoria introduce sesgo.
- En el caso de que haya mucho patrones con datos faltantes, podría reducir considerablemente la cantidad de filas disponibles

B Eliminar los valores

- Si la recogida de datos no se ha realizado de forma aleatoria introduce sesgo.
- En el caso de que haya mucho patrones con datos faltantes, podría reducir considerablemente la cantidad de filas disponibles

C Eliminar los valores

- Si la recogida de datos no se ha realizado de forma aleatoria introduce sesgo.
- En el caso de que haya mucho patrones con datos faltantes, podría reducir considerablemente la cantidad de filas disponibles



Herramientas



```
sklearn.impute.SimpleImputer(missing_values=np.nan, strategy='mean', fill_value=None, copy=True, add_indicator=False)
```

- **missing_values:** Indica como son representados los valores faltantes (np.nan es el estandar)
- **strategy:** mean, median, most_frequent, constant.
- **fill_value:** Si uso constant, puedo usar fill_value para indicar por cuál valor debe ser reemplazado
- **copy:** Si pongo True, crea una copia de X
- **add_indicator:** Agrega un indicador para los valores faltantes.

```
from sklearn.imputer import SimpleImputer
```

```
imp = SimpleImputer(strategy='median')
```

```
df['salario'] = imp.fit_transform(df[['salario']])
```




OUTLIERS

Outliers

Detección de outliers mediante criterios estadísticos tradicionales e interpretación guiada por IA. **Detección de outliers mediante criterios estadísticos tradicionales e interpretación guiada por IA.** en una muestra estadística que puede afectar potencialmente a la estimación de los parámetros de la misma.

Distribución de una variable




Existen **métodos** para poder filtrar outliers. La distribución de la variable determinará qué estrategia es más apropiada usar.

Estrategia z-score


El z-score es una forma de describir los datos en términos de su relación con la **media** y el **desvío estándar**. El objetivo es eliminar todos aquellos valores que están muy lejos de cero (media μ), normalmente a 3 o -3 desvíos estándar.

Fórmula

$$Z_i = \frac{x_i - \mu}{\sigma}$$




Rango intercuartílico



Rango intercuartílico

Rango intercuartílico (RIC) es la **diferencia** entre el **tercer** y el **primer cuartil** de una distribución. Es una medida de la dispersión estadística. El objetivo es eliminar todos aquellos valores menores al primer cuartil menos 1.5 veces el RIC o mayores al tercer cuartil más 1.5 veces el RIC.

```
q1 = df['Purchase'].quantile(0.25)
q3 = df['Purchase'].quantile(0.75)
iqr = q3 - q1
lb = q1 - (iqr * 1.5)
ub = q3 + (iqr * 1.5)
```





Descanso

Nos vemos en 10 minutos



Sección práctica:

Aprendemos sobre datos faltantes y Outliers en la
Notebook 9



Sala general:

Valores faltantes y outliers

Trabajamos con la Notebook 9

Demostraremos cómo manejar datos faltantes y filtrar outliers.





¿Alguna consulta?



Sección práctica:

Exploramos los datos con la Notebook 10



Trabajamos en salas

Trabajamos en salas de zoom

Exploración de datos

Trabajaremos con la Notebook 10

En los grupos establecidos, aprendemos cómo explorar y visualizar los datos



50 minutos de actividad



Descanso

Nos vemos en 10 minutos

Sala general:

Descripción y visualización

Trabajamos con la Notebook 10

Revisamos los ejercicios realizados en la notebook 10



Desafío 7

- Para la siguiente clase:
- Practicar en Pandas el manejo de datos faltantes y outliers. Llevar lo visto a su proyecto final.



Desafío 8

Para la siguiente clase, comenzar a aplicar a su tema y dataset la práctica vista en clase:

- Describir y visualizar los datos en Pandas
- Manejo de faltantes y outliers





¿Alguna consulta?



¡Muchas Gracias!

En la próxima clase veremos:
`transformacion_datos`

