



Módulo III | Clase 7

Análisis exploratorio de datos: Transformación de datos I





¿Ponemos a grabar el
taller?

¿Qué vamos a ver hoy?





- Conceptos básicos de Feature Engineering
 - Obtención de variables derivadas
- Encoder de variables
 - Feature Engineering de datos estructurados y textos no estructurados
 - Re-escalado de variables



Feature Engineering

Conceptos básicos de Feature Engineering


El Feature Engineer persigue como objetivo encontrar features relevantes para la pregunta que queremos contestar en los datos.



Depende de que hayamos **planteado correctamente** el problema a ser optimizado.

¿Qué implica?


Selección de Features



Combinación de variables



Transformación Feature Engineering de
datos estructurados y textos no
estructurados





Obtención de variables

Obtención de variables derivadas

Combinar variables ya presentes que puedan capturar efectos dependientes entre ambos y afectar el resultado:

- Sumando o restando variables
- Multiplicando o dividiendo variables





EncodingFeature Engineering de datos estructurados y textos no estructurados

EncodingFeature Engineering de datos estructurados y textos no estructurados

En muchos datasets tenemos datos textuales o categorías. Se pueden crear variables a partir de longitudes o patrones de texto. **En muchos datasets tenemos datos textuales o categorías. Se pueden crear variables a partir de longitudes o patrones de texto.** En muchos datasets tenemos datos textuales o categorías. Se pueden crear variables a partir de longitudes o patrones de texto. con este tipo de variables. La mayoría de ellos espera **valores numéricos.**



Convertimos los datos categóricos en datos numéricos.

- `LabelEncoder()`
- `.get_dummies()`
- `OneHotEncoder()`




.LabelEncoder()

Codifica categoría en valores numéricos entre 0 y el número de clases menos 1.

	pais	edad	salario	compra
0	Francia	44	72000	no
1	España	27	48000	si
2	Alemania	30	54000	no
3	España	38	61000	no
4	Alemania	40	40000	si
5	Francia	35	58000	si
6	España	40	52000	no
7	Francia	48	79000	si
8	Alemania	50	83000	no
9	Francia	37	67000	si

	pais	edad	salario	compra
0	2	44	72000	no
1	1	27	48000	si
2	0	30	54000	no
3	1	38	61000	no
4	0	40	40000	si
5	2	35	58000	si
6	1	40	52000	no
7	2	48	79000	si
8	0	50	83000	no
9	2	37	67000	si



.get_dummies()

- **Variable dummy** o “indicadora”
- Función de pandas: modifica el DataFrame, Se aplica para cada atributo por separado.



OneHotEncoder()

- **Variable dummy** o “indicadora”
- Función de sklearn: no modifica el DataFrame





Feature Engineering de datos estructurados y textos no estructurados

Feature Engineering de datos estructurados y textos no estructurados

A veces las **variables numéricas** no aportan mucha información como variable continua. Determinar rangos y asignar categorías puede aportar más información





Reemplazamos los valores contenidos en un pequeño intervalo con un único valor representativo para el mismo

- Binning



Feature Engineering de datos estructurados y textos no estructurados





Descanso

Nos vemos en 10 minutos



Sección práctica:

**Aprendemos cómo transformar
datos en la Notebook 11**

Sala general:

Transformación de datos

Trabajamos con la Notebook 11

Demostraremos cómo obtener variables derivadas y como hacer encoding de las variables usando pandas y scikit-learn.



DESAFÍO 9



Para la siguiente clase:

- comenzar a aplicar a su tema y dataset la práctica vista en clase:
- Transformar datos con Pandas







¿Alguna consulta?



Repasamos

Conceptos básicos de Feature Engineering


El Feature Engineer persigue como objetivo encontrar features relevantes para la pregunta que queremos contestar en los datos.



Depende de que hayamos **planteado correctamente** el problema a ser optimizado.

¿Qué implica?


Selección de Features



Combinación Feature Engineering de
datos estructurados y textos no
estructurados




Transformación Feature Engineering de
datos estructurados y textos no
estructurados



¿Por qué transformar las variables?

Muchos algoritmos de machine learning tienen un mejor desempeño cuando las variables o features están en una **escala similar o distribuidas normalmente**. Cuando el rango de una variable es más pequeño, las variaciones pequeñas son importantes pero quedan cubiertas por grandes variaciones en otras variables.





Re - escalado Feature Engineering de datos estructurados y textos no estructurados

Re-escalado de variables

Se utiliza si debemos escalar los datos al rango $[0,1)$, particularmente en algoritmos donde la distancia es importante.




Se cambia el rango de los datos

- MinMaxScaler()

$$x^* = \frac{x - x_{min}}{x_{max} - x_{min}}$$

Support vector machines (SVM) y k-nearest neighbors (KNN)



FUNDACIÓN
YPF

¡Muchas Gracias!

En la próxima clase veremos:
Transformación de datos y evaluación de distribuciones

