FUNDACIÓN YPF

Módulo V | Aprendizaje supervisado Clase 12

Regresión y clasificación - Algoritmos más comunes parte 1



FUNDACIÓN YPF



¿Ponemos a grabar el taller?

FUNDACIÓN YPF

¿Qué vamos a ver hoy?



- Diferencia entre regresión y clasificación
- Regresión lineal, regresión logística y árboles de decisión

- Algoritmos más comunes para regresión y clasificación
- Notebook 16 y ejercicio en salas

FUNDACIÓN YPF



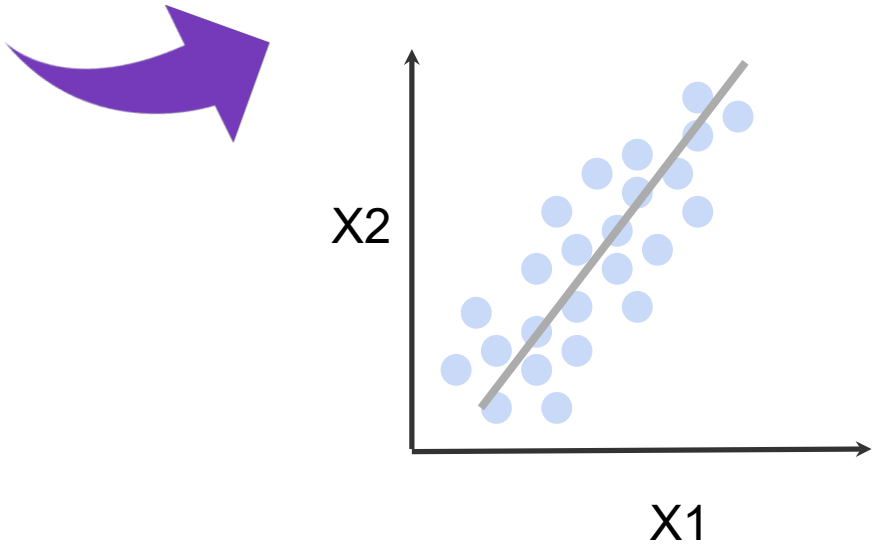
Regresión y Clasificación

FUNDACIÓN YPF

Regresión

La variable dependiente es un **valor numérico**

- Precio de una casa
- Valor de acciones



FUNDACIÓN YPF

Regresión

Consiste en predecir una respuesta numérica Y en base a **atributos** X1, X2, ..., Xp

$$Y \approx f(X_1, X_2, ..., X_p)$$

FUNDACIÓN YPF

Regresión

Algoritmos más comunes

A

Regresión Lineal

B

Árboles de Decisión

C

Random Forest

D

SVR (Regresión con máquinas de soporte vectorial)

FUNDACIÓN YPF

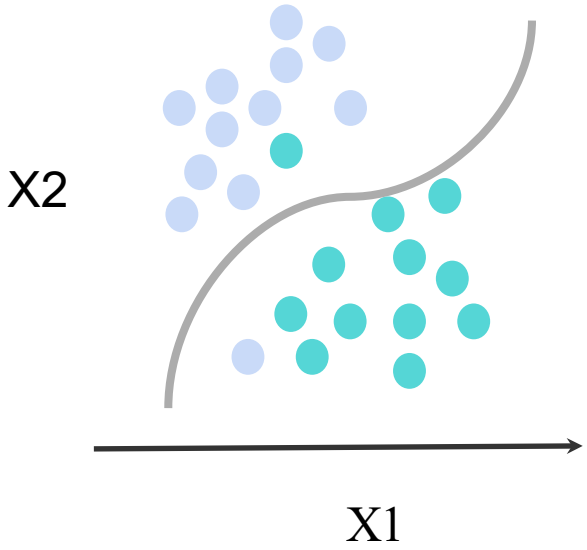
Clasificación

FUNDACIÓN YPF

CLASIFICACIÓN

Cada instancia pertenece a **una clase**

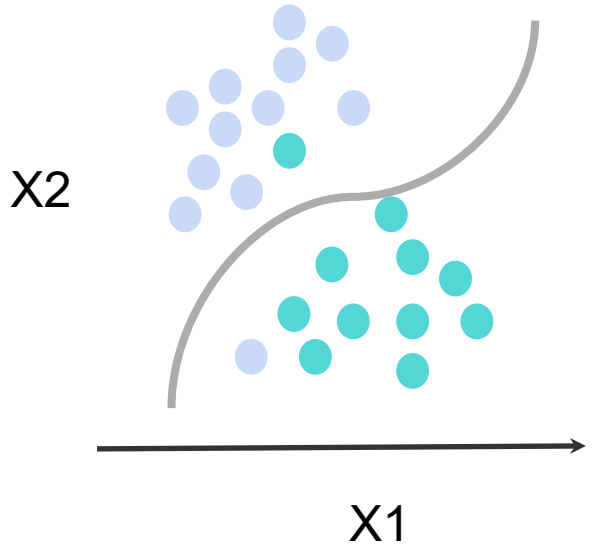
- Email es spam o no
- Detección de Fraude
- Análisis de Sentimiento



FUNDACIÓN YPF

CLASIFICACIÓN

Consiste en predecir la pertenencia de una observación a una clase Y en base a atributos X1, X2



FUNDACIÓN YPF

Clasificación

Algoritmos más comunes

A

Regresión Logística

B

Árboles de Decisión

C

Random Forest

D

Support Vector Machine

FUNDACIÓN YPF



Algoritmos más comunes

FUNDACIÓN YPF



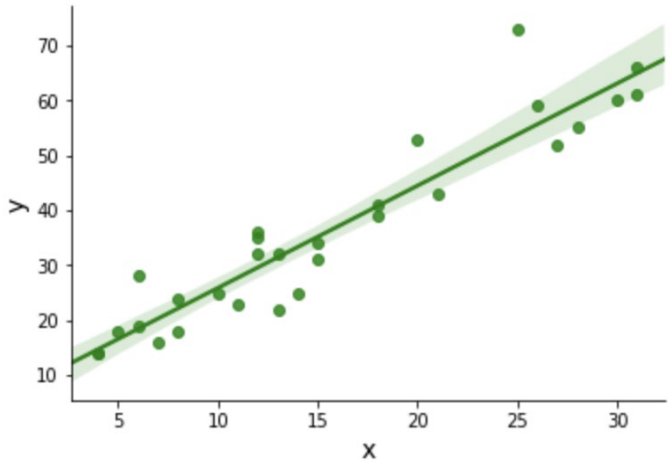
Regresión lineal

FUNDACIÓN YPF

Regresión Lineal

Buscamos Y = **m**X + **b** que mejor ajuste a los datos

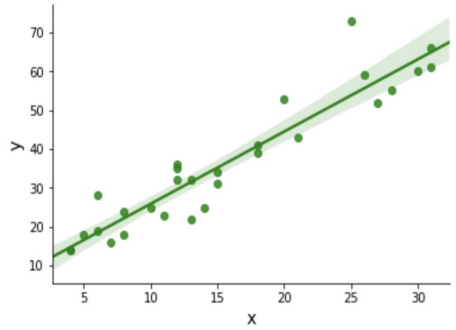
m: pendiente
b: ordenada al origen



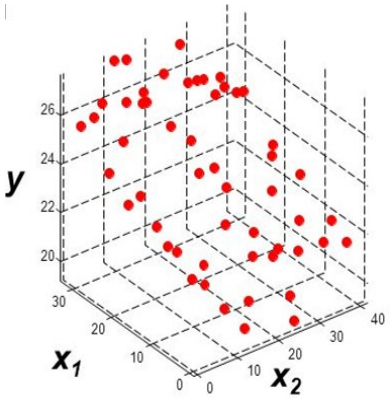
FUNDACIÓN YPF

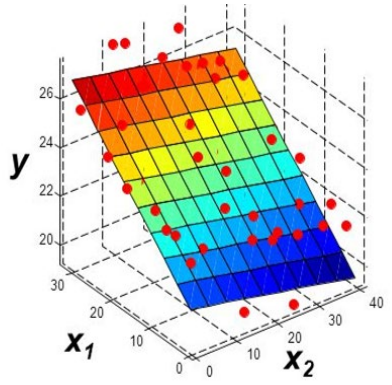
Regresión Lineal

Un atributo: x_1
$Y = m_1x_1 + b$



Dos atributos: x_1, x_2
$Y = m_1x_1 + m_2x_2 + b$





n atributos

$$\hat{y} = \theta_0 + \theta_1 * x_1 + \theta_2 * x_2 + \theta_3 * x_3 \ldots + \theta_n * x_n$$

FUNDACIÓN YPF

Regresión Lineal

- **Supuestos**
  - Debe haber una relación lineal entre las variables independientes y la variable dependiente
  - Los residuos deben seguir una distribución normal
  - No debe haber multicolinealidad entre las variables independientes
  - La varianza de los residuos es constante (homocedasticidad)

FUNDACIÓN YPF



Regresión logística

FUNDACIÓN YPF

Regresión Logística

La regresión logística aplica el operador logístico a los datos para determinar la probabilidad de un punto a pertenecer a una determinada **clase**.

$$P(t) = \frac{1}{1 + e^{-t}}$$

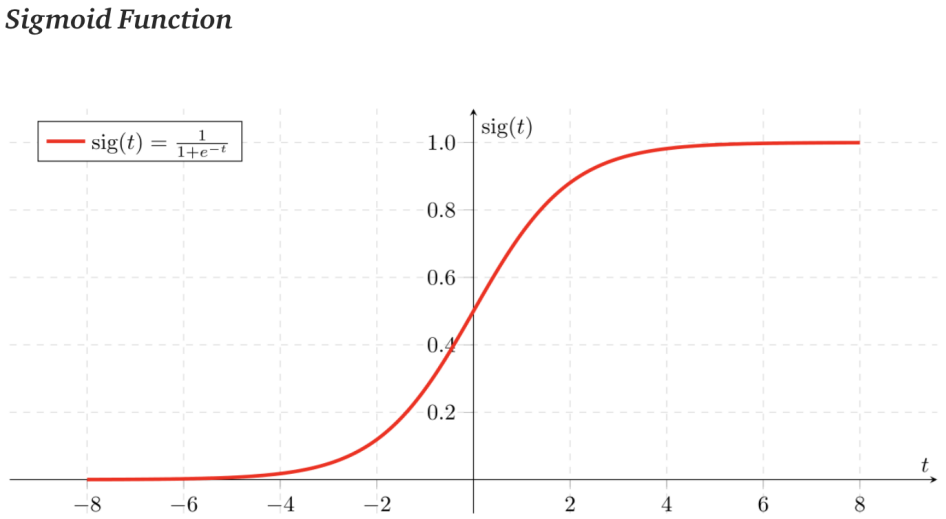


Figure 2: Sigmoid Activation Function

FUNDACIÓN YPF

Regresión Logística

Clasificación

- Utiliza la misma estructura que la regresión lineal, pero aplica la función sigmoide para transformar la salida en una probabilidad entre 0 y 1.
- **Supuestos**
  - Debe haber una relación lineal entre las variables independientes y el logaritmo de las odds (log-odds)
  - Las observaciones deben ser independientes entre sí
  - No debe haber multicolinealidad entre las variables independientes
  - Se necesita un tamaño de muestra suficiente (al menos 10 eventos por variable predictora)

FUNDACIÓN YPF

Regresión lineal vs. logística vs. árboles

- **¿Cuándo usar cada uno?**
  - La elección del algoritmo depende del tipo de problema, la naturaleza de los datos y los supuestos que se puedan asumir
  - Regresión lineal: predecir un valor numérico continuo. Ej: precio, temperatura, ingresos
  - Regresión logística: clasificar en dos categorías. Ej: spam o no spam, aprueba o no aprueba
  - Árboles de decisión: clasificación o regresión; interpretables, no asumen linealidad

FUNDACIÓN YPF



Descanso

Nos vemos en 10 minutos

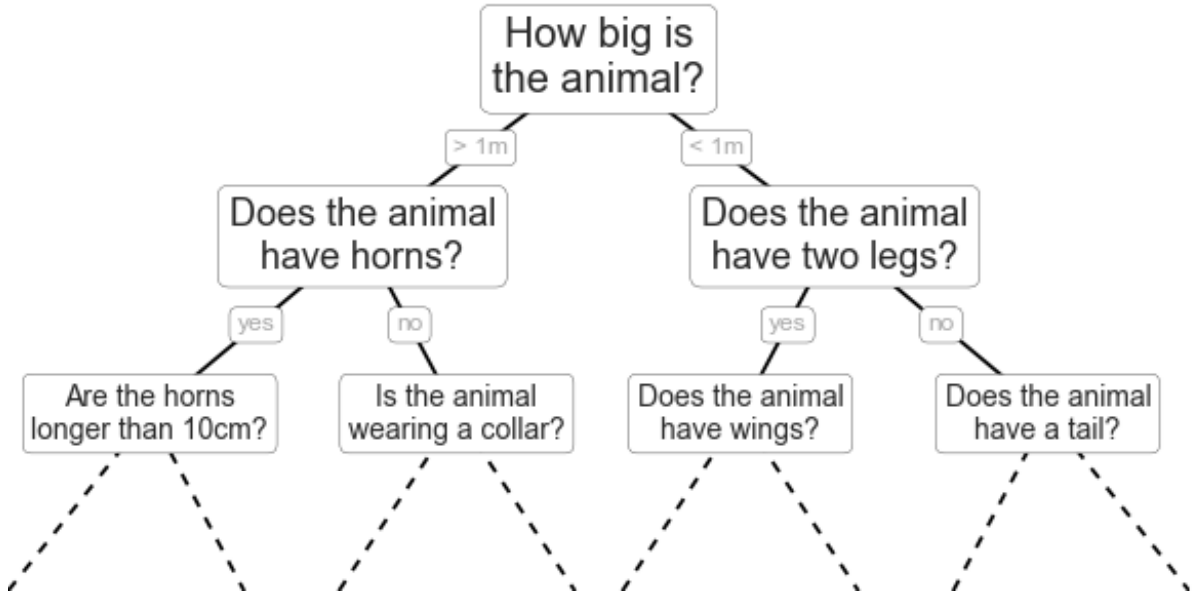
FUNDACIÓN YPF

Árboles de decisión

FUNDACIÓN YPF

Árboles de decisión

Un árbol de decisión **hace preguntas** y va clasificando de acuerdo a las respuestas.

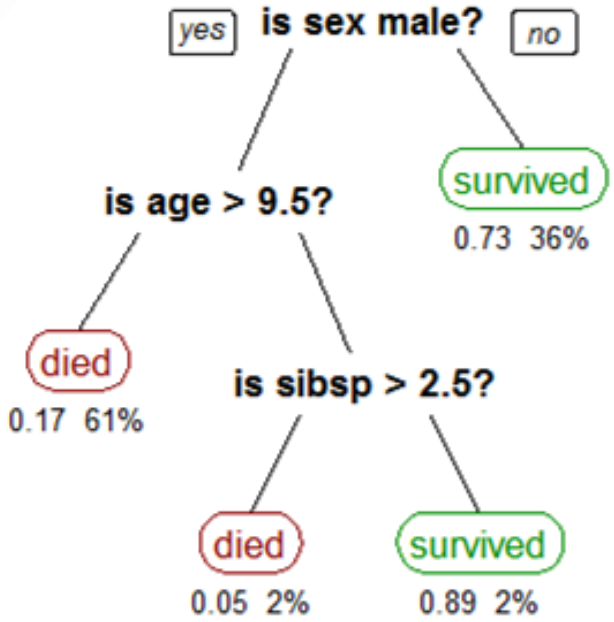


FUNDACIÓN YPF

Árboles de decisión

Un árbol de decisión **hace preguntas** y va clasificando de acuerdo a las respuestas.

¿Cómo decide preguntar?



FUNDACIÓN YPF

Árboles de decisión

¿Cómo decide qué preguntar?



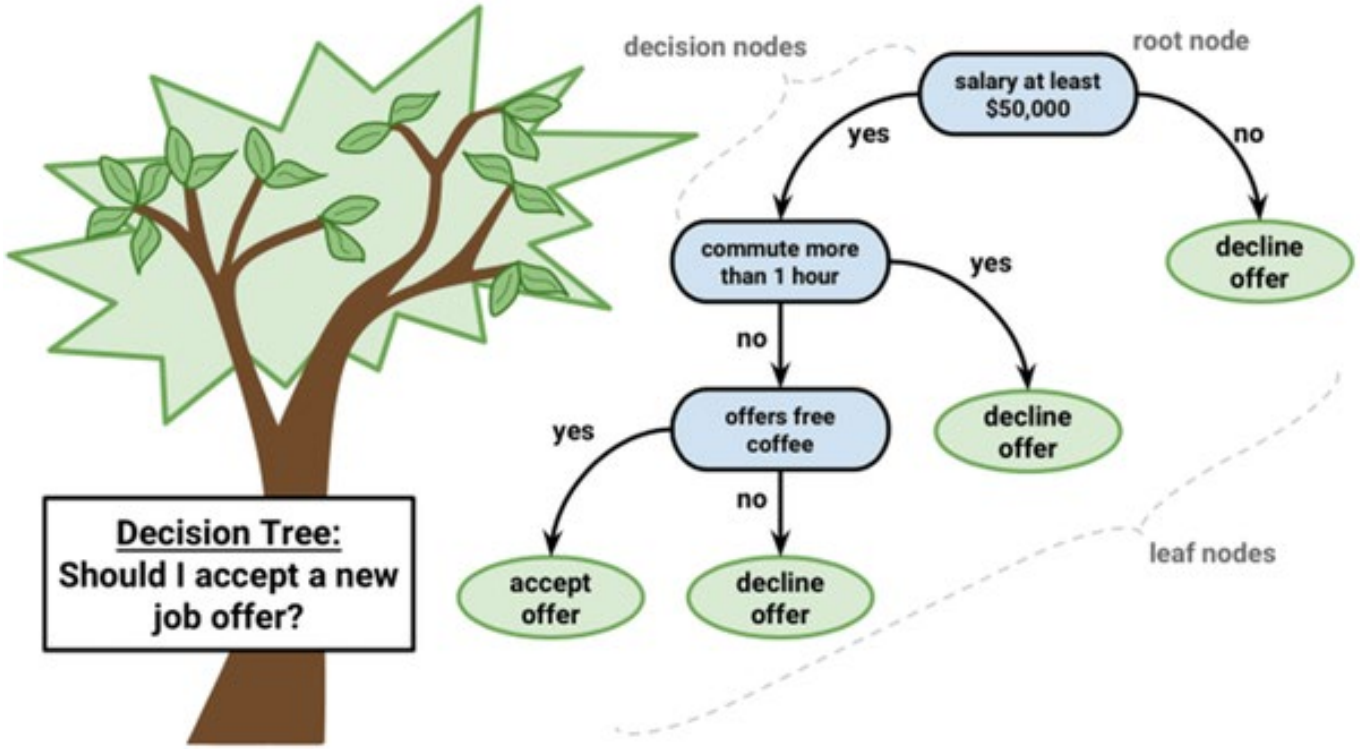
1. Impureza Gini

1. Ganancia de información

Son cálculos que se realizan sobre los datos. Le indican al modelo que tanta **relevancia** tiene un **feature** para **separar** las instancias por sus etiquetas.

FUNDACIÓN YPF

Árboles de decisión



FUNDACIÓN YPF

Árboles de decisión



- Clasificación y Regresión
- Simple de entender, interpretar y visualizar
- Modelo base para modelos más complejos (Random Forest, etc)
- **Parámetros para nodos**:
  - Impureza de Gini
  - Ganancia de información
- En scikit-learn requieren encoding previo de variables categóricas
- Tendencia al sobreajuste; se controla con max_depth, min_samples y poda

FUNDACIÓN YPF



Sección práctica:

Trabajamos con la Notebook 16
ajustando los primeros modelos de
regresión y clasificación

FUNDACIÔN YPF

En la sala general
Aprendizaje Supervisado - Parte 1

Trabajamos con la Notebook 16

Demostraremos cómo ajustar los modelos de regresión lineal, regresión logística y árboles de decisión



FUNDACIÓN YPF

En las salas de Zoom
Notebook 16, Parte 6: ejercicio

Objetivo: ajustar y comparar modelos sobre un dataset nuevo

1. Elegir el tipo de problema (regresión o clasificación)
2. Entrenar al menos dos modelos de los vistos en clase
3. Comparar resultados con un piso de referencia (DummyClassifier o DummyRegressor)
4. Anotar qué modelo funcionó mejor y por qué



FUNDACIÓN YPF

Puesta en común

- **¿Qué encontraron?**
  - ¿Algún modelo memorizó en vez de aprender? ¿Cómo se dieron cuenta?
  - ¿Qué tipo de problema eligieron y por qué?
  - ¿Qué modelo dio mejor resultado? ¿Cómo se compara con el piso?
  - ¿Qué dificultades encontraron al preparar los datos para el modelo?

FUNDACIÓN YPF

Desafío 12

- Para la siguiente clase, repasar y ejercitar la Notebook 16. Experimentar cambiando hiperparámetros de los modelos.



FUNDACIÓN YPF



¡Muchas Gracias!

En la próxima clase veremos:

algoritmos más comunes parte 2