FUNDACIÓN YPF

Módulo V | Aprendizaje supervisado Clase 13

Algoritmos Random Forest, KNN SVM y optimización con Optuna



FUNDACIÓN YPF



¿Ponemos a grabar el taller?

FUNDACIÓN YPF

¿Qué vamos a ver hoy?



- Repasamos Árboles de Decisión
- Random Forest y Optuna (optimización de hiperparámetros)
- K-Nearest Neighbors
- Support Vector Machine

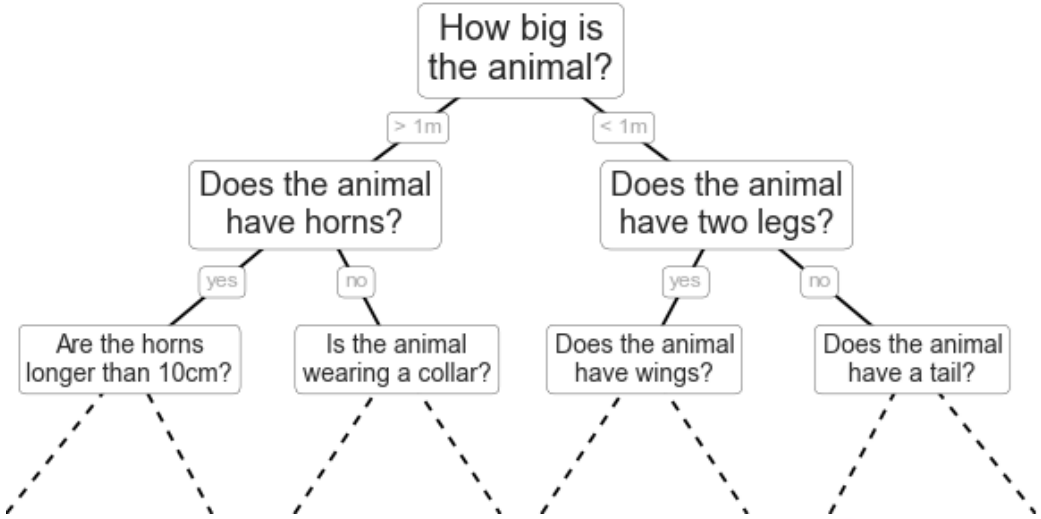
FUNDACIÓN YPF

Repasamos

FUNDACIÓN YPF

Árboles de decisión

Un árbol de decisión **hace preguntas** y va clasificando de acuerdo a las respuestas.



FUNDACIÓN YPF

Árboles de decisión



- Clasificación y Regresión
- Simple de entender, interpretar y visualizar
- Modelo base para modelos más complejos (Random Forest, etc)
- **Parámetros para nodos**:
  - Impureza de Gini
  - Ganancia de información
- En scikit-learn requieren encoding previo de variables categóricas
- Tendencia al sobreajuste; se controla con max_depth, min_samples y poda

FUNDACIÓN YPF

¿Alguna consulta?

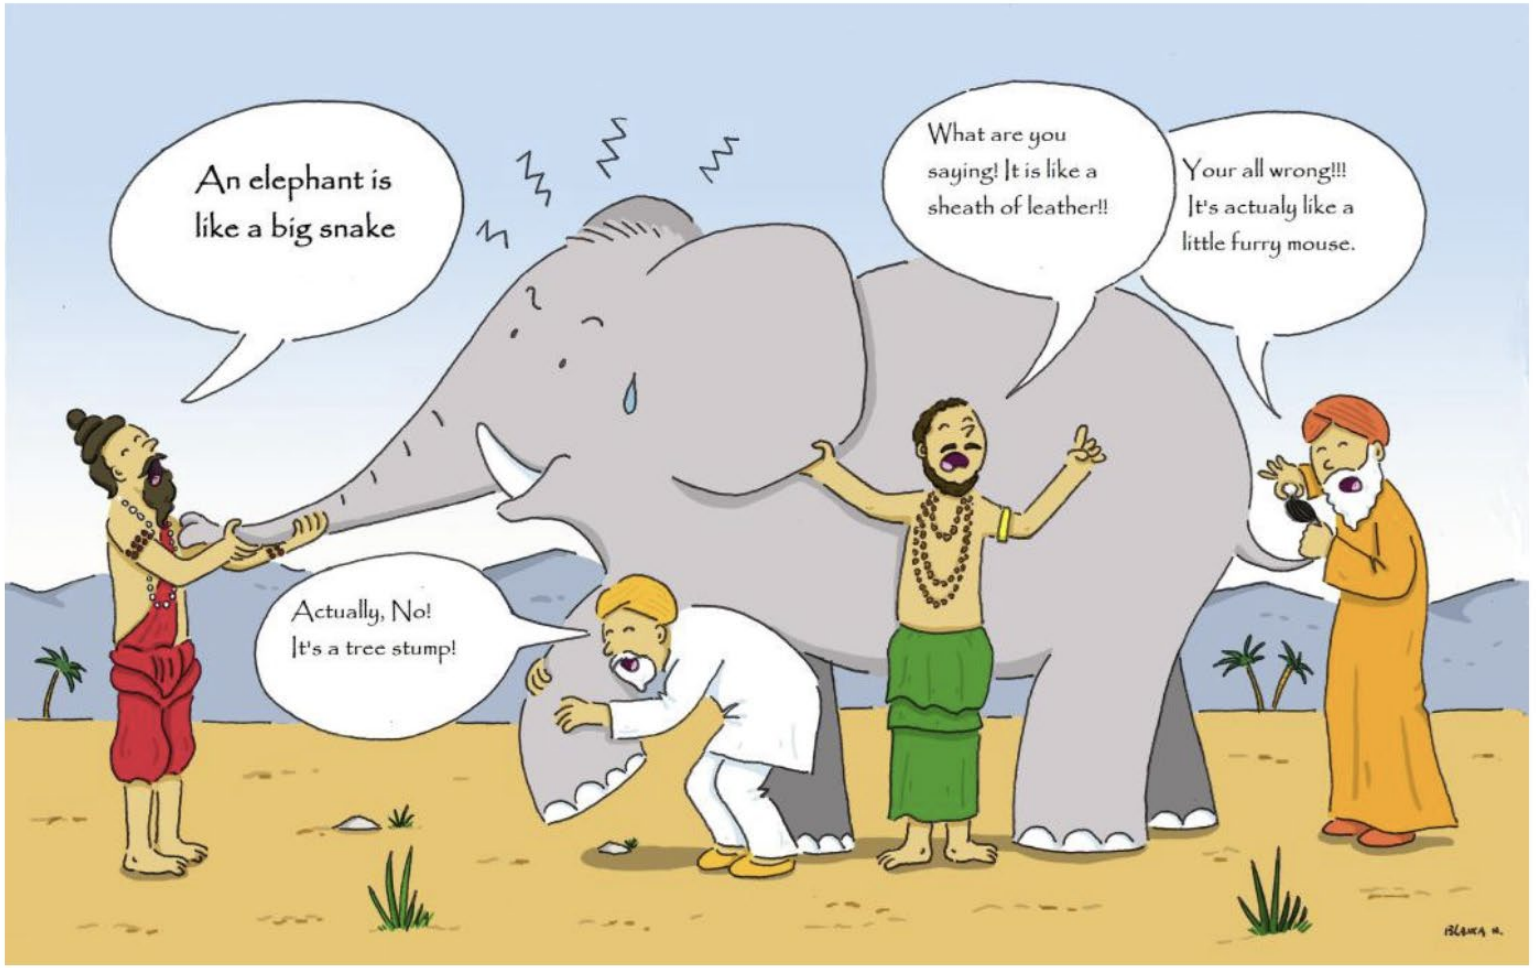
FUNDACIÓN YPF



Random Forest

FUNDACIÔN YPF

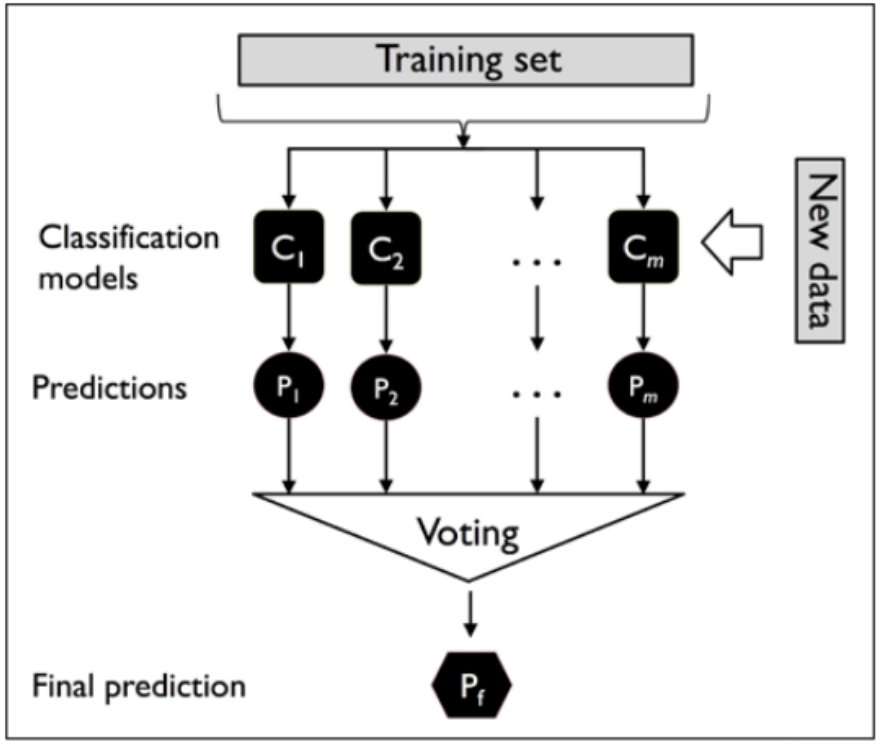
Random Forest



FUNDACIÓN YPF

Random Forest

- Entrenar muchos modelos y cada uno tendrá un resultado.
- La clasificación o valor resultante es el resultado más frecuente.



FUNDACIÓN YPF

Random Forest

- Si todos los modelos son muy parecidos, no agregan mucha información nueva en la votación final.
- Se necesitan **modelos diferentes entre sí, poco correlacionados.**

- Regresión y Clasificación
- **Ventajas**
  - Robusto frente a outliers y ruido
  - Buenos estimadores de error e importancia de variables
- **Desventajas**
  - Menos interpretable que un árbol individual
  - Más lento de entrenar y predecir por la cantidad de árboles

FUNDACIÓN YPF



Optimización de hiperparámetros con Optuna

FUNDACIÓN YPF

Optimización de hiperparámetros con Optuna

Búsqueda manual (GridSearchCV): Prueba todas las combinaciones de una grilla fija de valores. Es exhaustivo pero crece exponencialmente con la cantidad de hiperparámetros.

Optuna: Librería que automatiza la búsqueda usando optimización Bayesiana: en lugar de probar todo, aprende de las pruebas anteriores para elegir la próxima combinación más prometedora.

Además usa poda de pruebas (pruning): corta una prueba a mitad de camino si ya se ve que va a dar un resultado peor que las anteriores, ahorrando tiempo de cómputo.

El resultado es encontrar buenos hiperparámetros en una fracción del tiempo que toma una búsqueda exhaustiva.

FUNDACIÓN YPF

K-Nearest Neighbors (kNN)

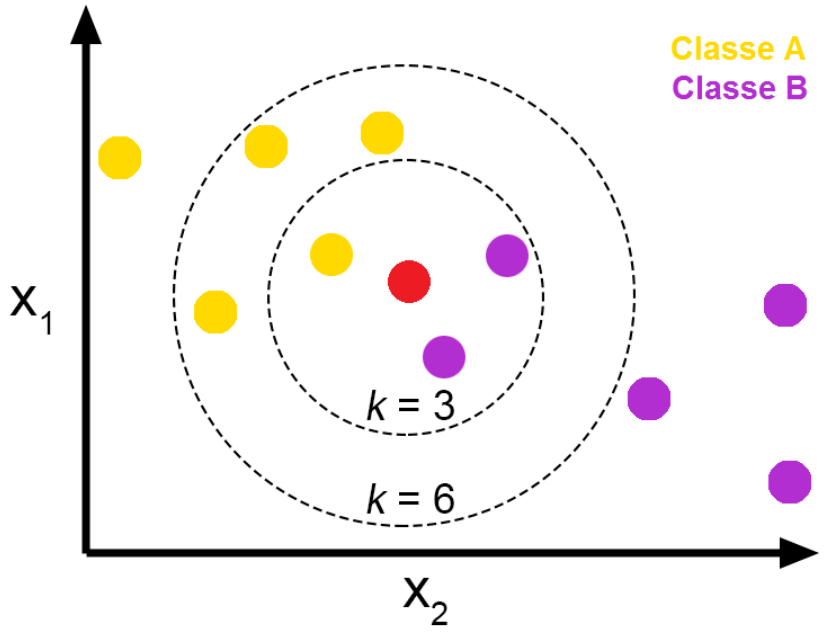
FUNDACIÓN YPF

K Nearest Neighbors (kNN)

El método de **K Nearest Neighbors (kNN)** consiste en etiquetar muestras en función de la etiqueta que tengan los **K** vecinos más cercanos

FUNDACIÓN YPF

K Nearest Neighbors (kNN)



- Calcula la **distancia** a cada uno de los puntos existentes.
- Selecciona la etiqueta que más frecuente aparece en las K clases

FUNDACIÓN YPF

K Nearest Neighbors (kNN)

Clasificación y Regresión

- **Ventajas**
  - Rápido porque no tiene nada que ajustar, solo almacena los datos
  - Es fácil de entender sobre todo en clasificación
- **Desventajas**
  - Costoso en tiempo de predicción con datasets grandes: calcula la distancia a todos los puntos
  - La elección de K afecta fuertemente el resultado; sensible a variables irrelevantes o ruidosas
  - Requiere homogeneizar features

FUNDACIÓN YPF



Descanso

Nos vemos en 10 minutos

FUNDACIÓN YPF

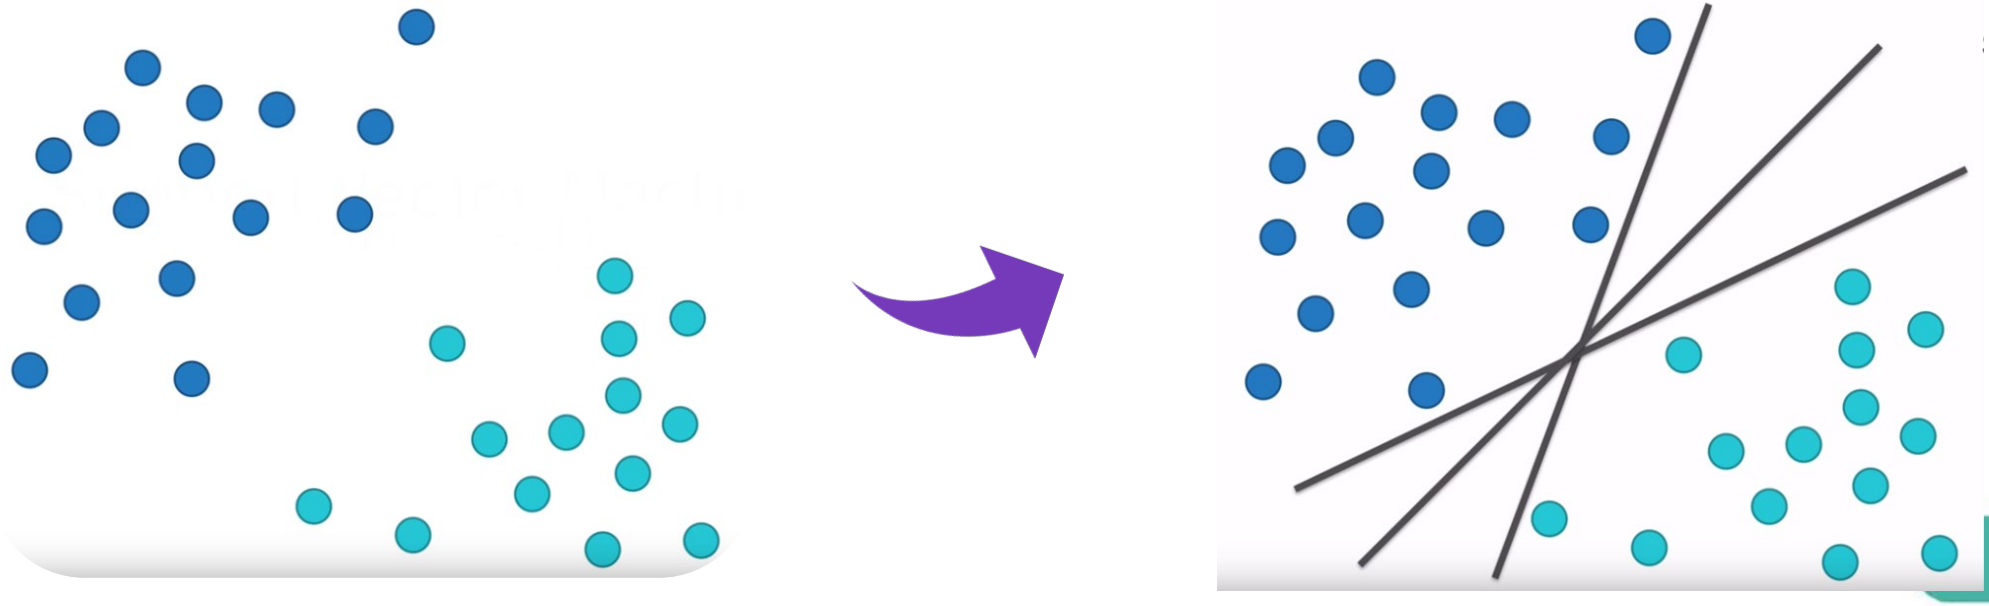


Support Vector Machines

FUNDACIÓN YPF

Support Vector Machines

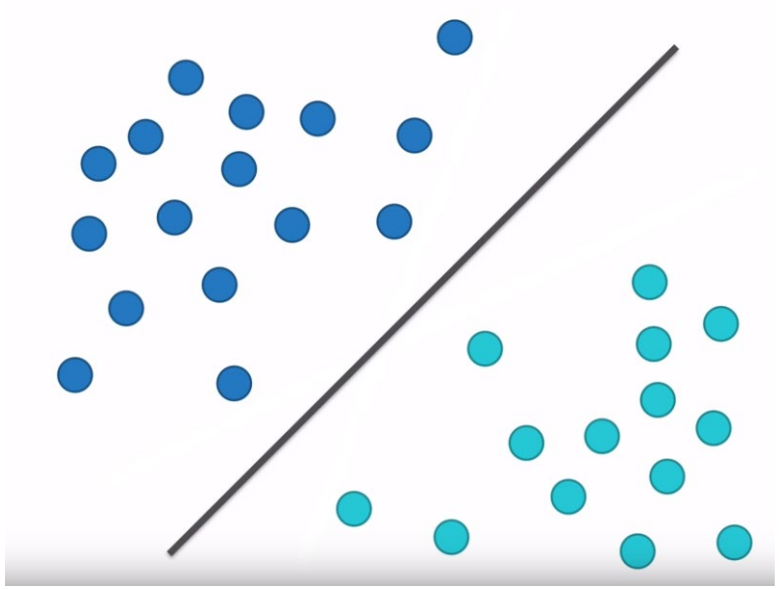
Tarea: Separar los puntos azules de los celestes



FUNDACIÓN YPF

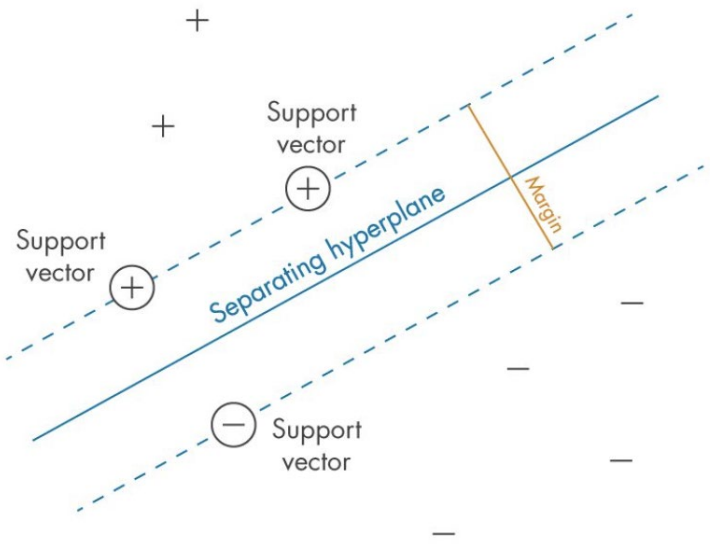
Support Vector Machines

- SVM elige la recta que separa los puntos de la “**mejor manera posible**”



FUNDACIÓN YPF

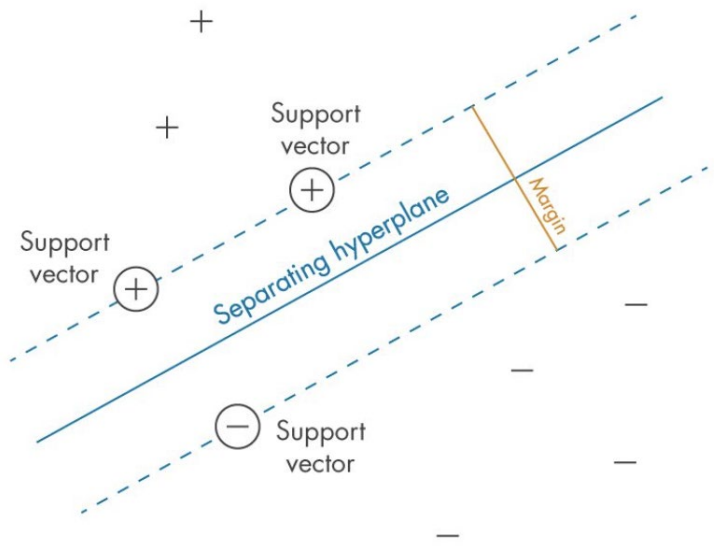
Support Vector Machines



- Establece un hiperplano que separa los puntos **maximizando** el margen.
  - La distancia del margen al vector de soporte es la mayor que se puede encontrar.
  - Es el mayor margen que se puede encontrar.

FUNDACIÓN YPF

Support Vector Machines



Margen: Es la distancia de las instancias más cercanas a la recta de decisión.

Vectores de soporte: Las instancias más cercanas al margen. Es una de las pocas características de los datos que le importa al algoritmo.

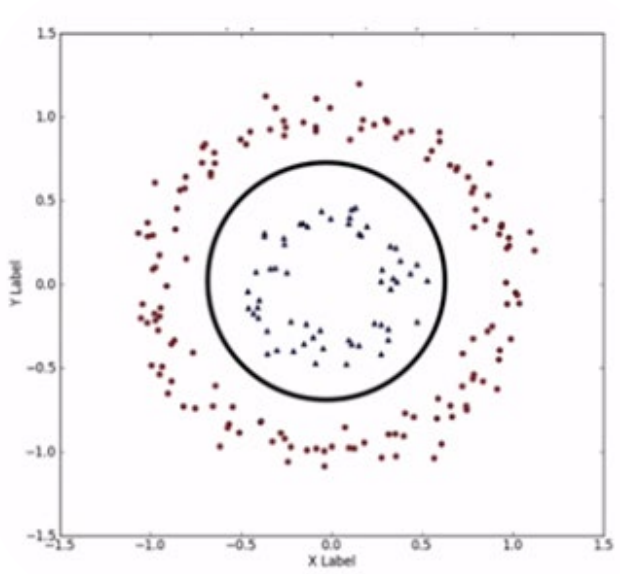
Lo que hace el algoritmo es encontrar la recta que maximice el margen.

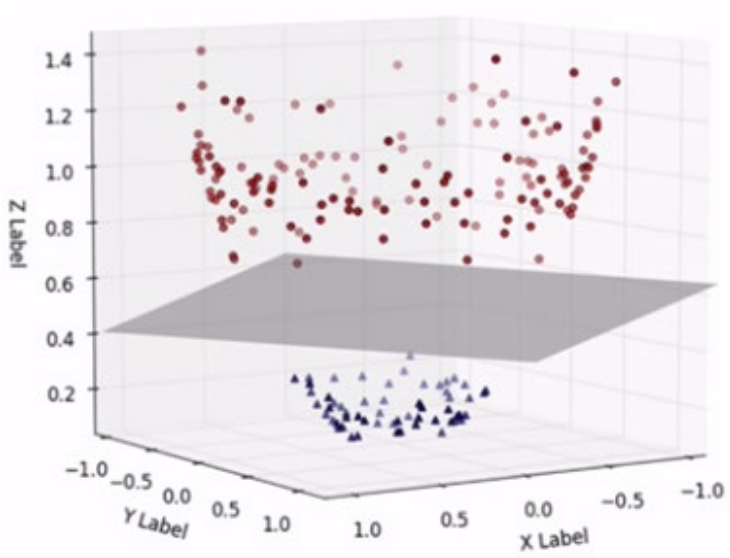
Es un problema de optimización, lo que conlleva a una solución computacionalmente eficiente.

FUNDACIÓN YPF

Support Vector Machines

Kernels: Se utilizan cuando los datos directamente no se pueden separar con una línea





FUNDACIÓN YPF

Support Vector Machines

- Clasificación y Regresión
- **Ventajas**:
  - Eficaz en espacios de alta dimensión
  - Eficiente en memoria
  - El uso de kernels lo convierten en muy versátil
- **Desventajas**:
  - El uso de kernels tiende a llevar al algoritmo a overfitting
  - Su mejor desempeño se da para problemas de clasificación

FUNDACIÓN YPF

Sección práctica:

Trabajamos con la Notebook 17
ajustando KNN, SVM, Random Forest y
optimizando con Optuna

FUNDACIÓN YPF

En la sala general
Aprendizaje Supervisado - Parte 2

Trabajamos con la Notebook 17

Demostraremos cómo ajustar kNN, SVM, Random Forest y cómo optimizar hiperparámetros con Optuna



FUNDACIÓN YPF

En las salas de Zoom
Notebook 17, ejercicio en grupos

Objetivo: entrenar y comparar los modelos vistos hoy

1. Entrenar al menos dos de los modelos vistos (kNN, SVM, Random Forest)
2. Comparar contra el árbol de decisión de la Notebook 16
3. Elegir uno y optimizar sus hiperparámetros con Optuna
4. Anotar si la optimización mejoró el resultado y cuánto



FUNDACIÓN YPF

Puesta en común



- ¿Qué encontraron?
- ¿Qué modelos entrenaron y cuál dio mejor resultado?
- ¿Cómo se compara con el árbol de decisión de la Notebook 16?
- **¿Optuna mejoró el resultado? ¿Cuánto y a qué costo de tiempo?**
  - ¿Qué dificultades encontraron al elegir hiperparámetros para optimizar?
  - ¿Cuánto tiempo tomó la optimización comparado con probar manualmente?
- ¿Qué modelo fue más simple de usar: kNN, SVM o Random Forest? ¿Por qué?
- ¿Algún modelo mostró señales de sobreajuste?

FUNDACIÔN YPF

Desafío 13

- Para la siguiente clase, repasar y ejercitar la Notebook 17. Probar Optuna con otro modelo.



FUNDACIÓN YPF

¿Alguna consulta?

FUNDACIÓN YPF



¡Muchas Gracias!

En la próxima clase veremos:

Práctica Regresión y Clasificación