FUNDACIÓN YPF

Módulo VI

Aprendizaje NO supervisado.

Clase 20: K-Means



FUNDACIÓN YPF



¿Ponemos a grabar el taller?

FUNDACIÓN YPF

¿QUÉ VAMOS A VER HOY?



- CLUSTERING: K-Means
- Repaso del algoritmo K-Means
- Elección del número de clusters

- Buenas prácticas y limitaciones
- Práctica con la Notebook 24 C20

FUNDACIÓN YPF

REPASEMOS

FUNDACIÓN YPF

Eligiendo algoritmo

Tarea

Definir de forma clara el objetivo

1

Información

Con qué datos se cuenta para lograr el objetivo

2

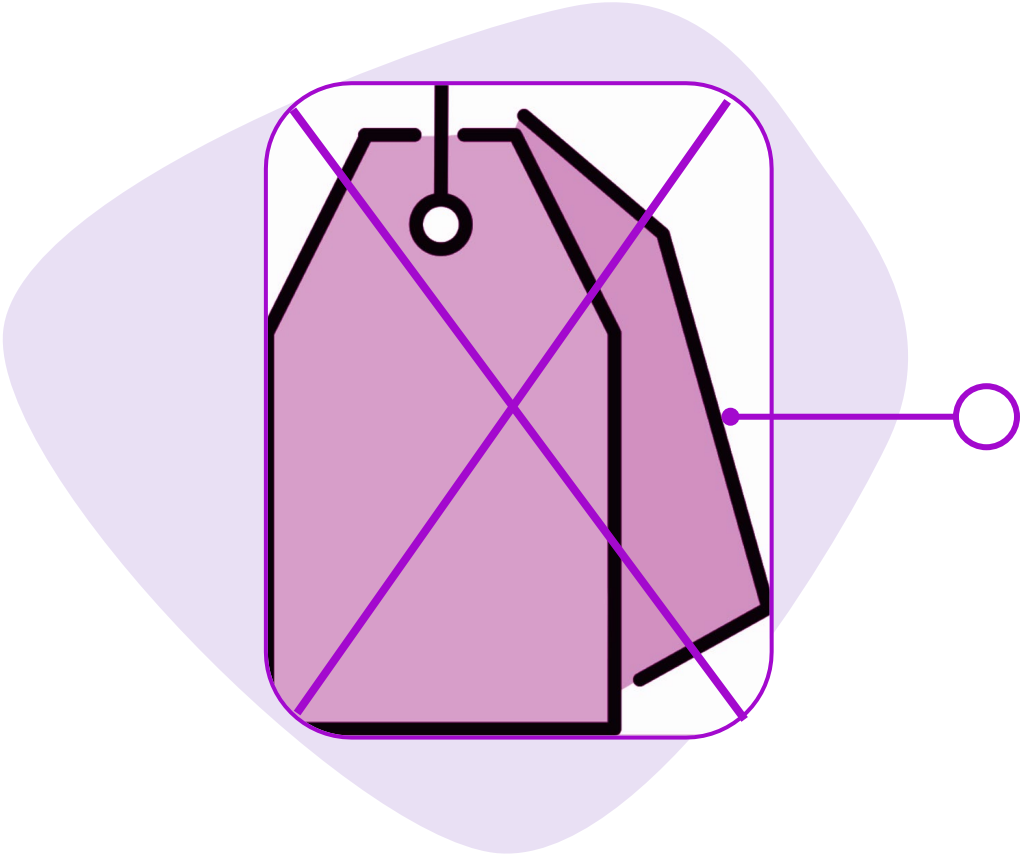
APRENDIZAJE **SUPERVISADO**

APRENDIZAJE **NO SUPERVISADO**



FUNDACIÓN YPF

Aprendizaje No Supervisado



El algoritmo infiere patrones de un conjunto de datos que, a diferencia del aprendizaje supervisado, **no** están **etiquetados**. Puede utilizarse para descubrir la estructura subyacente de los datos

FUNDACIÓN YPF

CLUSTERING

FUNDACIÓN YPF

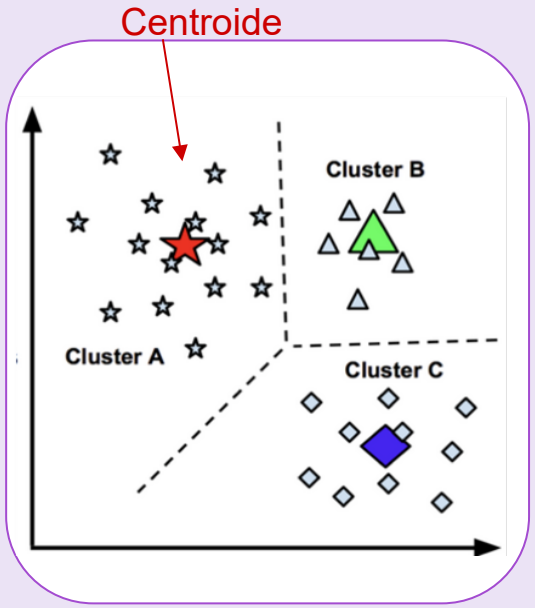
Clustering

El **objetivo** del clustering o agrupamiento es encontrar grupos (**clusters**) en los cuales las instancias de un mismo grupo sean parecidas entre sí.

- **Aplicaciones**
  - Investigación de mercado
  - Sistemas de recomendación
  - Medicina y Biología
- **Algoritmos**
  - K-means
  - DBSCAN
  - Hierarchical Clustering
  - Fuzzy C-Means
  - Gaussian Mixture Models

FUNDACIÓN YPF

K-Means



Encuentra un número **k** de centroides, uno por cada cluster, tal que la distancia entre cada instancia y el centroide de su cluster sea la **mínima posible**.

A continuación, cada instancia se identifica en el grupo del centroide más cercano

FUNDACIÓN YPF

K-Means

Se utiliza un algoritmo **iterativo** hasta llegar al resultado.

A Se inicializan los k Centroides (de manera aleatoria o siguiendo algún criterio)

B Se encuentra el centroide más cercano de cada instancia

C Se actualizan los centroides (nuevo centroide: promedio de las posiciones de las instancias de ese cluster)

D Se repiten los pasos B y C hasta que la posición de los centroides ya no varíe.

FUNDACIÓN YPF

K-Means: elegir k

Para elegir **k** se puede usar el método del codo:

A Se entrena K-Means con distintos valores de k (por ejemplo, de 1 a 10) y se guarda cada resultado

B Para cada k se calcula la inercia de los clusters

C Se grafica la inercia (suma de distancias al cuadrado a los centroides) en función de k

D Se elige el k a partir del cual la mejora deja de ser grande (el codo del gráfico)

FUNDACIÓN YPF

K-Means: buenas prácticas

Para obtener buenos clusters con **K-Means** conviene tener en cuenta que:

A Hay que escalar las variables: K-Means se basa en distancias y las variables de mayor magnitud pesarían más

B Conviene repetir la inicialización varias veces (n_init)

C Hay que revisar los outliers: desplazan los centroides y distorsionan los clusters

D K-Means funciona mejor con clusters de forma esférica y de tamaños parecidos entre sí

FUNDACIÓN YPF



Trabajamos en salas

Trabajamos con K-Means en la Notebook 24 C20

FUNDACIÓN YPF

Trabajamos en salas de zoom

K-Means

Trabajaremos con la Notebook 24 C20

En los grupos establecidos, ejercitamos cómo se desarrolla un modelo de K-Means para Clustering

50 minutos de actividad



FUNDACIÓN YPF



Descanso

Nos vemos en 10 minutos

FUNDACIÓN YPF

Repasamos dudas



Trabajamos con la Notebook 24 C20

Revisamos los conceptos y el código trabajados en la Notebook 24 C20

FUNDACIÓN YPF

REPASO

Para la siguiente clase, repasar la Notebook 24 C20

FUNDACIÓN YPF

¿DUDAS?

FUNDACIÓN
YPF



¡Muchas Gracias!

En la próxima clase veremos:

Clustering DBSCAN