FUNDACIÓN YPF

Módulo VI - Aprendizaje NO supervisado.

Clase 21: Clustering DBSCAN



FUNDACIÓN YPF



¿Ponemos a grabar el taller?

FUNDACIÓN YPF

¿QUÉ VAMOS A VER HOY?

- CLUSTERING: DBSCAN
- Agrupamiento basado en densidad
- Parámetros epsilon y minPoints
- Comparación entre K-Means y DBSCAN
- Práctica con la Notebook 25 C21



FUNDACIÓN YPF

REPASEMOS

FUNDACIÓN YPF

Eligiendo algoritmo

Tarea

Definir de forma clara el objetivo

1

Información

Con qué datos se cuenta para lograr el objetivo

2

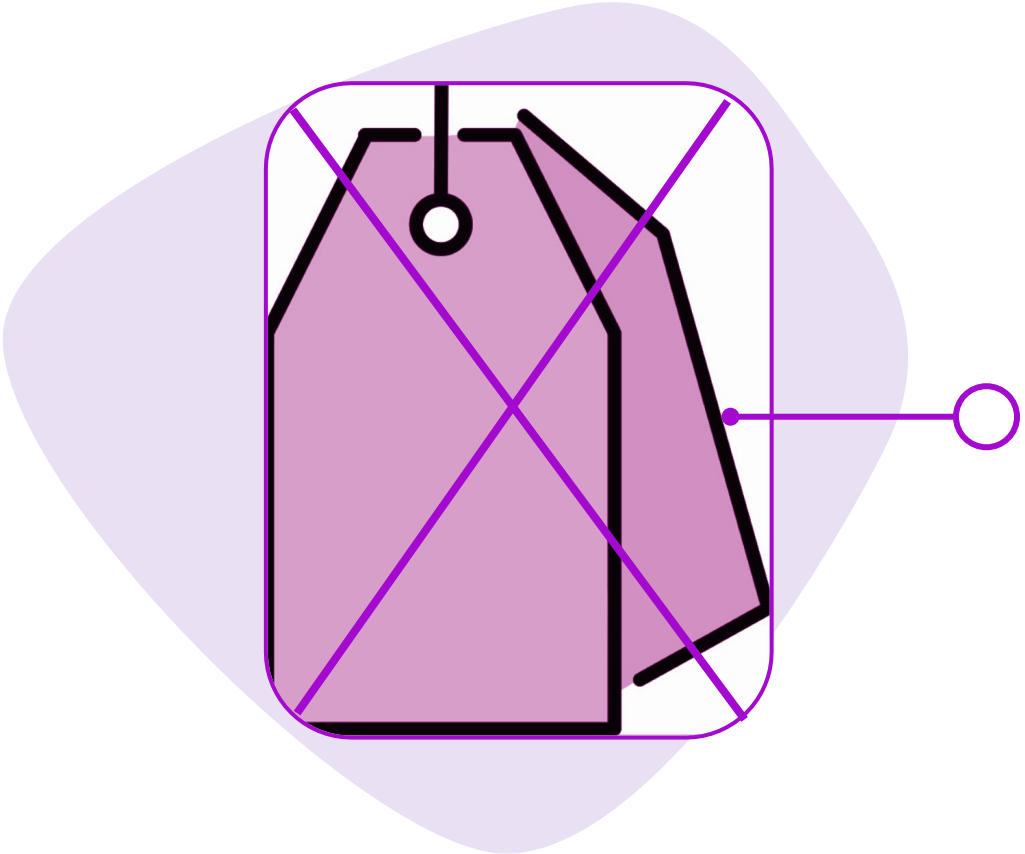
APRENDIZAJE **SUPERVISADO**

APRENDIZAJE **NO SUPERVISADO**



FUNDACIÓN YPF

Aprendizaje No Supervisado



El algoritmo infiere patrones de un conjunto de datos que, a diferencia del aprendizaje supervisado, **no** están **etiquetados**. Puede utilizarse para descubrir la estructura subyacente de los datos

FUNDACIÓN YPF

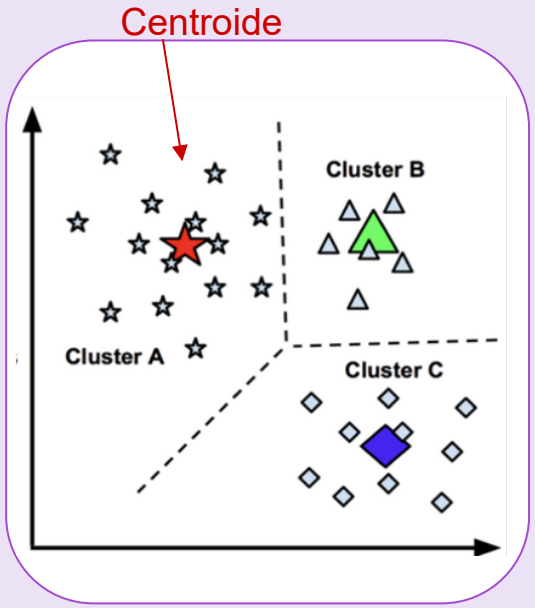
Clustering

El **objetivo** del clustering o agrupamiento es encontrar grupos (**clusters**) en los cuales las instancias de un mismo grupo sean parecidas entre sí.

- **Aplicaciones**
  - Investigación de mercado
  - Sistemas de recomendación
  - Medicina y Biología
- **Algoritmos**
  - K-means
  - DBSCAN
  - Hierarchical Clustering
  - Fuzzy C-Means
  - Gaussian Mixture Models

FUNDACIÓN YPF

K-Means



Encuentra un número **k** de centroides, uno por cada cluster, tal que la distancia entre cada instancia y el centroide de su cluster sea la **mínima posible**.

A continuación, cada instancia se identifica en el grupo del centroide más cercano

FUNDACIÓN YPF

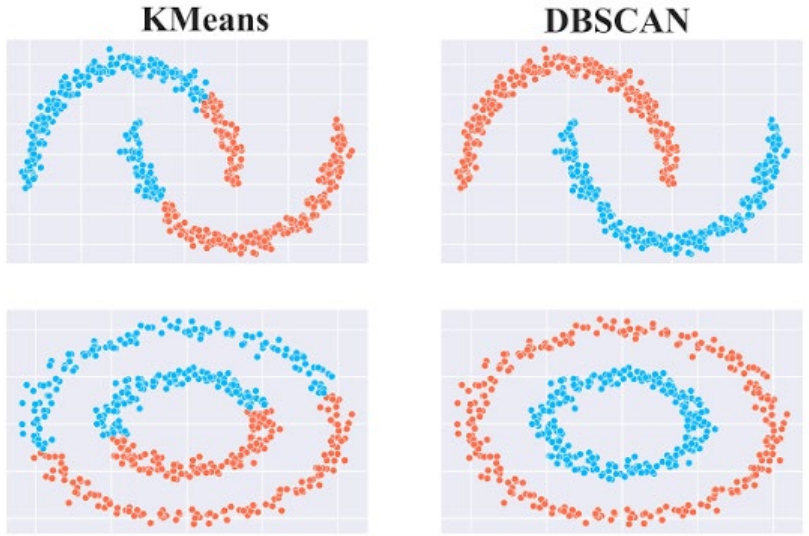
DBSCAN

FUNDACIÓN YPF

DBSCAN

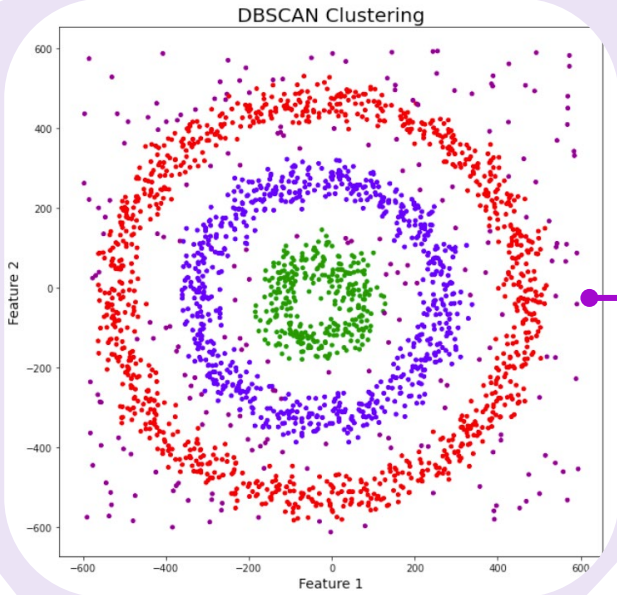
DBSCAN significa **Density-Based Spatial Clustering of Applications with Noise (agrupamiento espacial basado en densidad de aplicaciones con ruido).**

El algoritmo tiene como objetivo identificar un **número arbitrario** de clusters. Los clusters se definen por densidad de puntos. Puede haber puntos que no pertenezcan a ningún cluster.



FUNDACIÓN YPF

DBSCAN



Este algoritmo recorre todo el dataset e identifica aquellas zonas de puntos densamente pobladas como pertenecientes a un **mismo cluster**.

Los puntos aislados y que no pertenecen a **ningún cluster** serán considerados ruido u **outlier**.

FUNDACIÓN YPF

DBSCAN

A Se define una distancia **epsilon** como el radio de la vecindad de un punto. Se elige un número de puntos mínimos (**minPoints**) para considerar un cluster.

B Para cada punto del dataset:

i Se selecciona un punto no visitado **random**. Se identifica si tiene minPoints en su vecindario (punto core). Si no, se lo marca como noise (puede pasar a border). Se marca como visitado.

ii Si es un punto core, se le asigna un nuevo cluster y todos los puntos de su vecindario se consideran dentro de su cluster. Si alguno de estos puntos también es core, este proceso se repite. A los puntos asignados a un cluster que no son core, se los llama border. Todos se marcan como visitados.

iii El proceso se repite hasta que todos los puntos hayan sido visitados

FUNDACIÓN YPF

DBSCAN: parámetros

A Se define una distancia **epsilon** (eps) como radio de vecindad de un punto. Se elige un mínimo de puntos (**minPoints**) para que un punto sea core (min_samples).

B ¿Cómo elegimos los parámetros?

i Se **escalan** las variables antes de aplicar DBSCAN, porque epsilon es una distancia y las variables de mayor magnitud dominarían el cálculo. Se puede usar StandardScaler.

ii Para epsilon se grafica la distancia de cada punto a su k-ésimo vecino más cercano, ordenadas de menor a mayor: el codo del gráfico sugiere un buen valor (si es muy chico casi todo es ruido; si es muy grande, todo forma un solo cluster).

iii Para minPoints se parte de al menos el número de variables más uno

FUNDACIÓN YPF

K-Means vs. DBSCAN

Ventajas:

- Rápido
- Fácil de interpretar
- Fácil asignar nuevas instancias

Desventajas

- Hay que definir el número de clusters
- Solo tiene buen desempeño con clusters tipo esferas
- Sensible a outliers

Ventajas:

- No hay que elegir el número de clusters
- Detecta cualquier forma de clusters
- Detecta automáticamente los outliers (ruido)

Desventajas

- Hay que elegir bien los parámetros
- No tiene buen desempeño con clusters de diferentes densidades
- Es computacionalmente más costoso en datasets grandes

FUNDACIÓN YPF



Práctica:

Trabajamos con DBSCAN en la Notebook 25 C21

FUNDACIÓN YPF



Trabajamos en salas

FUNDACIÓN YPF

Trabajamos en salas de zoom



DBSCAN

Trabajaremos con la Notebook 25 C21

En los grupos establecidos, ejercitamos cómo se desarrolla un modelo de DBSCAN para Clustering

50 minutos de actividad

FUNDACIÓN YPF



Descanso

Nos vemos en 10 minutos

FUNDACIÓN YPF

Repasamos dudas



Trabajamos con la Notebook 25 C21

Revisamos los conceptos y el código trabajados en la Notebook 25 C21

FUNDACIÓN YPF

Para la siguiente clase, repasar la Notebook 25 C21



FUNDACIÓN YPF



¿Dudas?

FUNDACIÓN
YPF



¡Muchas Gracias!

En la próxima clase veremos:

Clustering - Métricas