FUNDACIÓN YPF

Módulo VI - Aprendizaje NO supervisado

Clase 23:

Single - Value Decomposition



FUNDACIÓN YPF



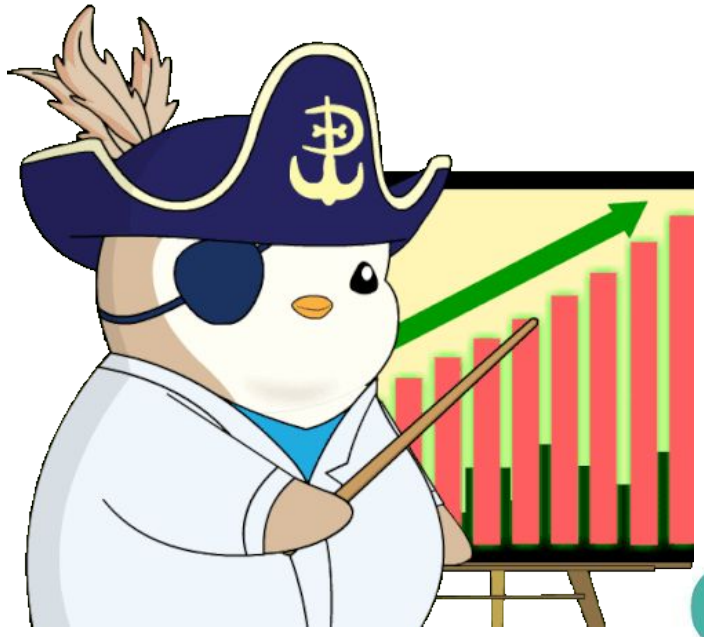
¿Ponemos a grabar el taller?

FUNDACIÓN YPF

¿QUÉ VAMOS A VER HOY?

- **Modernización: Reducción de Dimensionalidad**

  - PCA, TruncatedSVD, t-SNE y UMAP para visualización de alta dimensión



FUNDACIÓN YPF

Repasemos

- **Modernización: Reducción de Dimensionalidad**
  - PCA, TruncatedSVD, t-SNE y UMAP para visualización de alta dimensión

FUNDACIÓN YPF

Eligiendo algoritmo

Tarea

Definir de forma clara el objetivo

1

Información

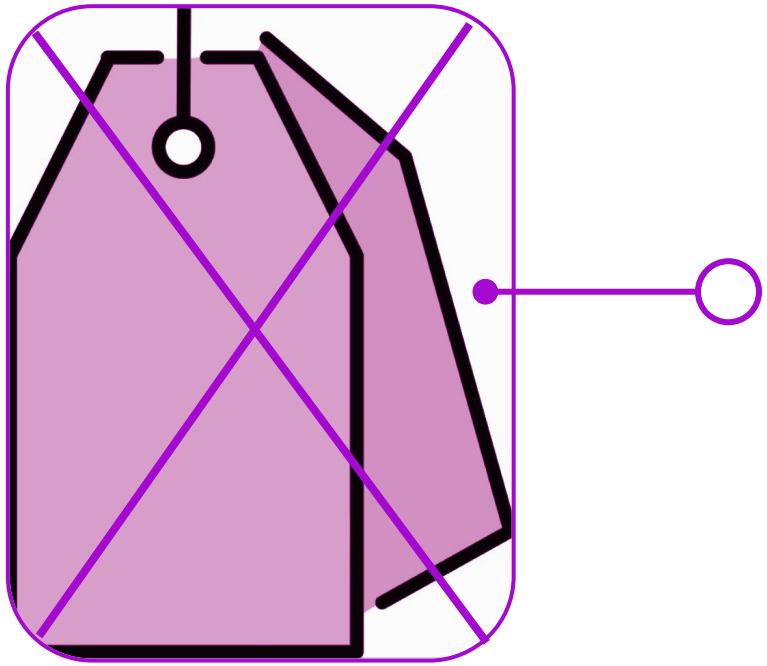
Con qué datos se cuenta para lograr el objetivo

2

- APRENDIZAJE **SUPERVISADO**
- APRENDIZAJE **NO SUPERVISADO**

FUNDACIÓN YPF

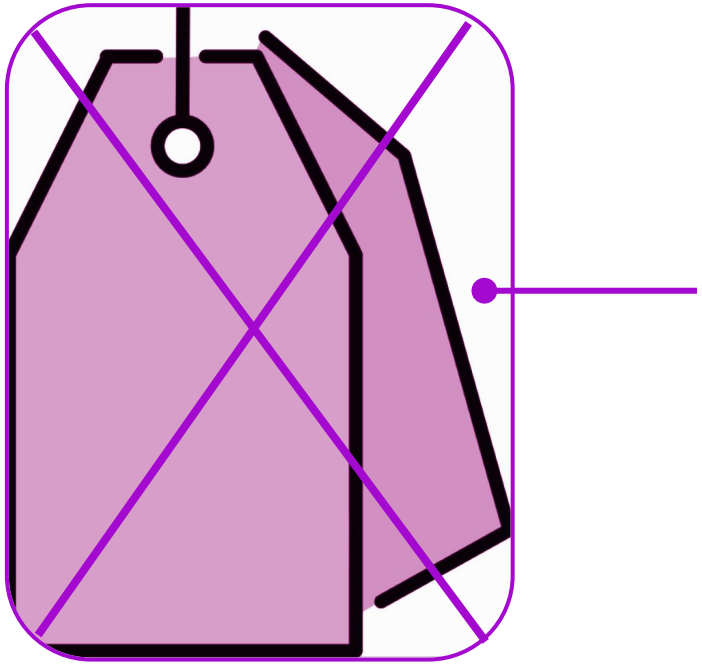
Aprendizaje No Supervisado



El algoritmo infiere patrones de un conjunto de datos que, a diferencia del aprendizaje supervisado, **no** están **etiquetados**. Puede utilizarse para descubrir la estructura subyacente de los datos

FUNDACIÓN YPF

Aprendizaje No Supervisado



- Clustering
- Reducción de la Dimensionalidad

FUNDACIÓN YPF



Reducción de la dimensionalidad

FUNDACIÓN YPF

Reducción de la dimensionalidad

El objetivo consta de **reducir la cantidad de features** de un dataset, pero **reteniendo** la **mayor** cantidad de **información** posible.

FUNDACIÓN YPF

Reducción de la dimensionalidad

Consiste en **reducir** la cantidad de **features** de un dataset, pero **reteniendo** la mayor cantidad de **información** posible.

- **Aplicaciones**
  - Reducir la complejidad del input en un modelo de regresión o clasificación
  - Visualización
  - Detectar features relevantes en datasets
- **Algoritmos**
  - **Principal Component Analysis**
  - Multidimensional Scaling
  - t-SNE: t-distributed Stochastic Neighbor Embedding
  - LDA: Linear Discriminant Analysis

FUNDACIÓN YPF

Principal Component Analysis

Técnica utilizada para describir un conjunto de datos en términos de nuevas variables o componentes no correlacionados.

- El algoritmo encuentra nuevos componentes que describen los datos
- Los componentes se ordenan por la cantidad de varianza original que describen, reduciendo la dimensionalidad del conjunto de datos.

- Utiliza **Single Vector Decomposition (SVD)**

FUNDACIÓN YPF

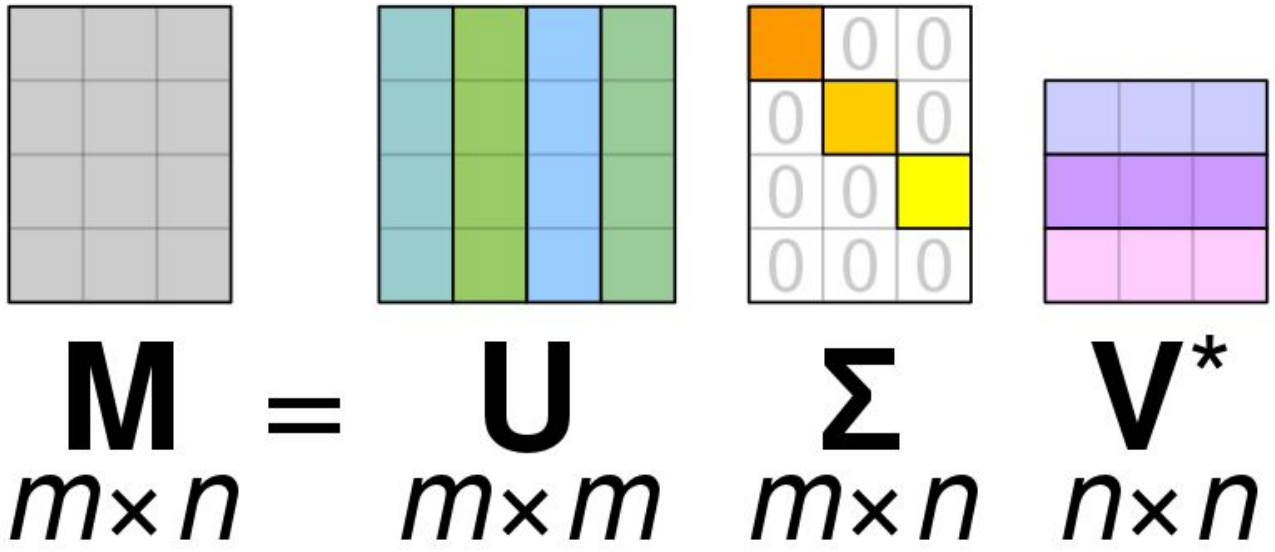


Single Value Decomposition

FUNDACIÓN YPF

Single Vector Decomposition

Es un **método de álgebra lineal** que nos permite representar cualquier matriz en términos de la multiplicación de otras 3 matrices.



FUNDACIÓN YPF

Single Vector Decomposition

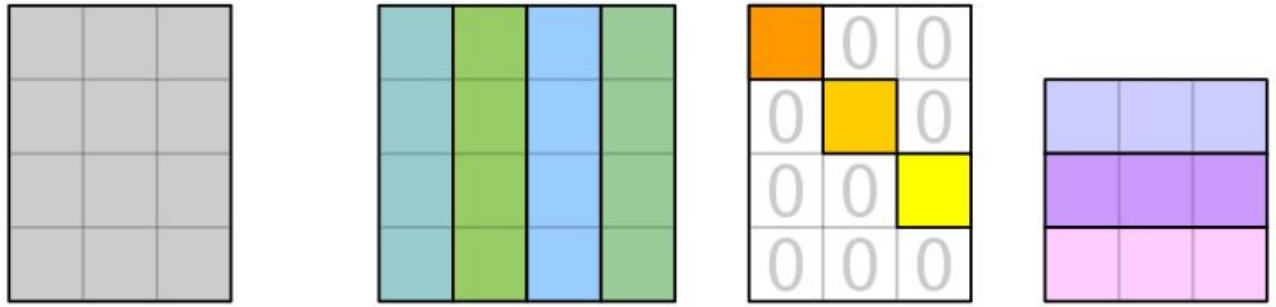
Toda matriz M se puede escribir como :

Matriz de Datos (m instancias, n features)

Matriz de vectores singulares por izquierda

Matriz de los valores singulares

Matriz de vectores singulares por derecha



Matriz Unitaria

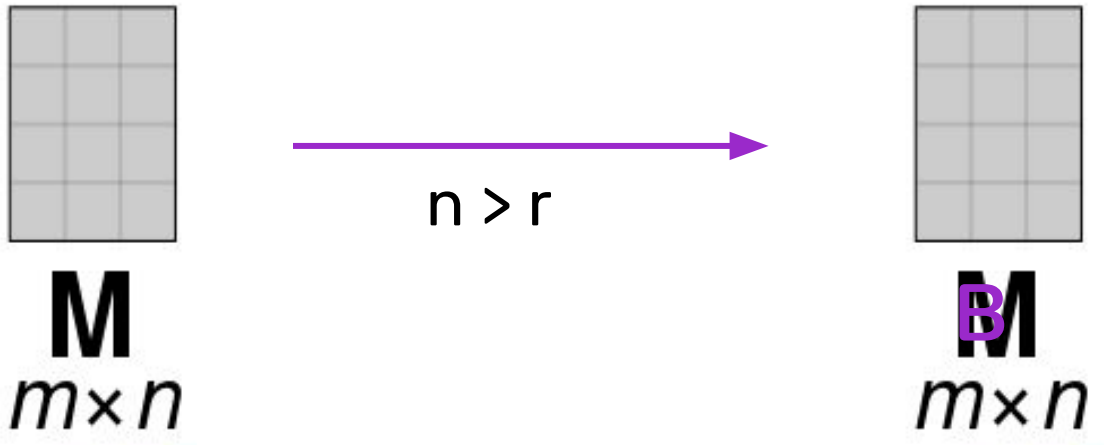
Matriz Diagonal

Matriz Unitaria

FUNDACIÓN YPF

Single Vector Decomposition

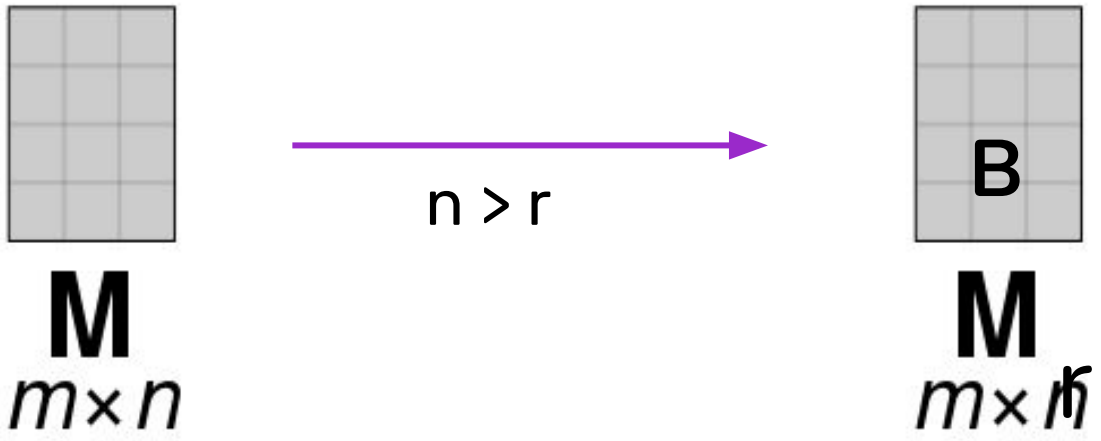
Es parte central de varios algoritmos numéricos y es fundamental para reducir apropiadamente la matriz M: pasar de tener muchos features a tener menos, pero relevantes y explicativos.



FUNDACIÓN YPF

Single Vector Decomposition

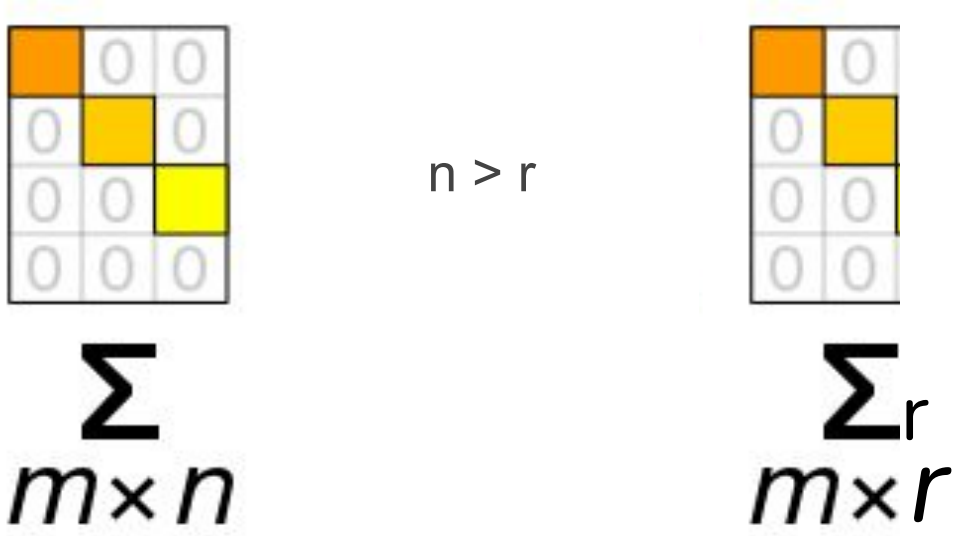
El objetivo es construir una nueva matriz B que reemplace a M, que tenga menos features.



FUNDACIÓN YPF

Single Vector Decomposition

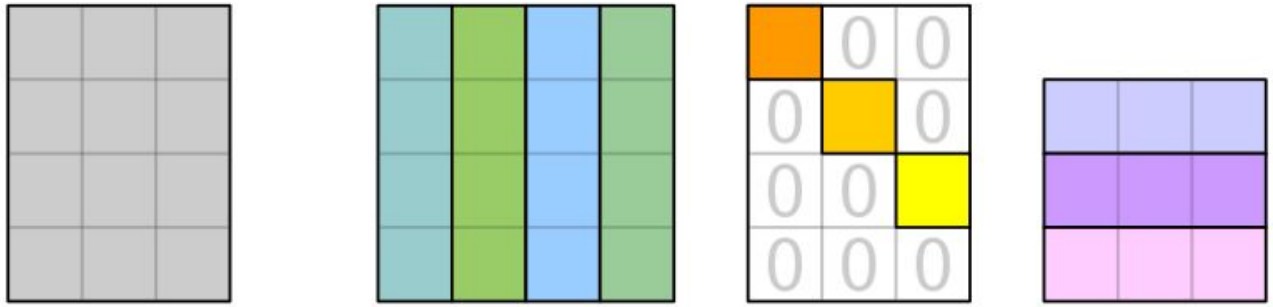
Para eso debemos tomar solo los valores principales (elementos en la diagonal de Sigma) de valor más grande y construir una matriz B que sea una **reducción** de X **relevante**.



FUNDACIÓN YPF

Single Vector Decomposition

Matriz completa: es la M original, tiene toda la información.

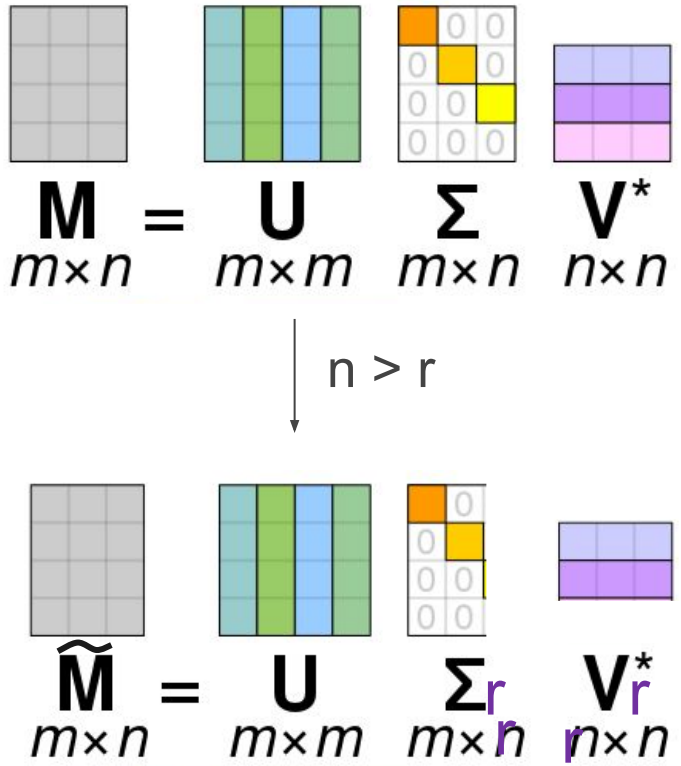


$$\underset{m\times n}{\mathbf{M}} = \underset{m\times m}{\mathbf{U}} \quad \underset{m\times n}{\mathbf{\Sigma}} \quad \underset{n\times n}{\mathbf{V}^*}$$

FUNDACIÓN YPF

Single Vector Decomposition

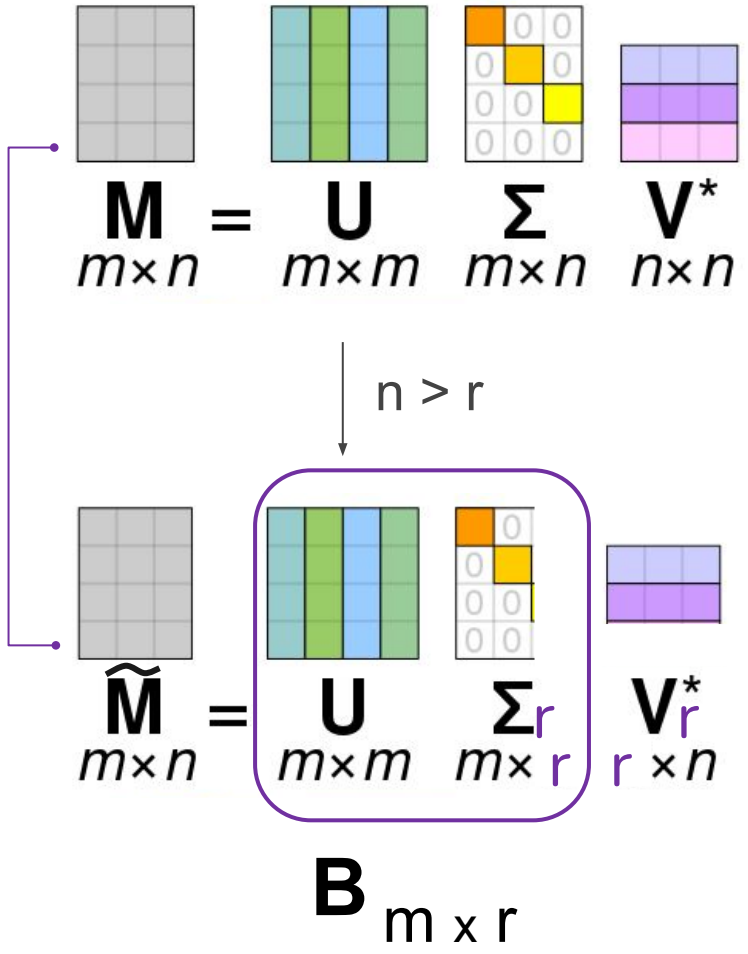
Matriz truncada: En esta matriz perdemos información. Pero al tomar un valor de r apropiado, la matriz truncada es muy parecida a M. Construimos una matriz B con menos features que M, pero relevante para el problema. Esta matriz es la que se utiliza para trabajar y representar los datos.



FUNDACIÓN YPF

Single Vector Decomposition

La matriz original y la truncada son parecidas



FUNDACIÓN YPF

Single Vector Decomposition

¿Cómo elegir el **valor de r**?

1) **Distancia entre M y $\widetilde{M}$**

$$|| M - \widetilde{M} ||_F = \sqrt{\sum_{ij} (M_{ij} - \widetilde{M}_{ij})^2}$$

El método de Single Value Decomposition GARANTIZA que elegimos los mejores r vectores o combinaciones de features para minimizar esta norma.

FUNDACIÓN YPF

Single Vector Decomposition

¿Cómo elegir el **valor de r**?

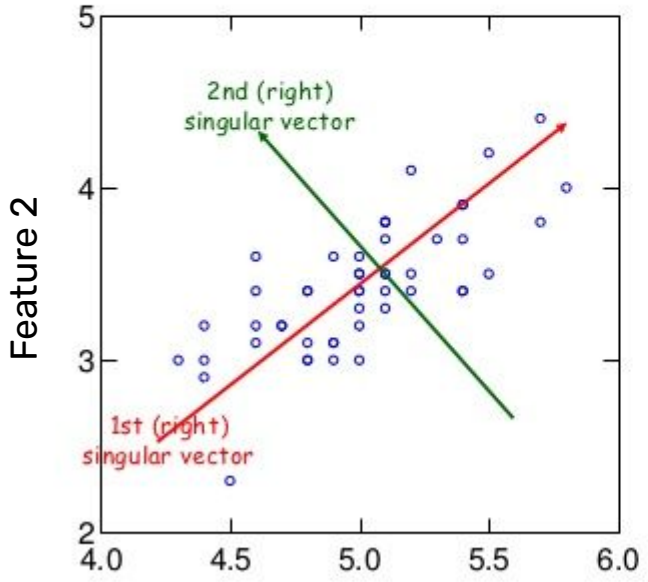
2) **Criterio sobre el peso relativo** de los valores singulares seleccionados respecto a la suma de todos.

Esta técnica es más costosa ya que se deben calcular todos los valores singulares.

FUNDACIÓN YPF

Single Vector Decomposition

Representación Gráfica



- Espacio original: 2 features (2 coordenadas). Esto define la posición de todas las instancias del dataset.
- SVD calcula nuevos vectores, el 1er y 2do vector singular. Utilizando estos valores como coordenadas, se puede definir la posición de cada punto.

FUNDACIÓN YPF

Principal Component Analysis

FUNDACIÓN YPF

Principal Component Analysis

PCA utiliza SVD. Por lo cual, aplicar PCA y SVD es muy parecido. Pero existe una diferencia:

PCA = Centrar datos + SVD truncado

FUNDACIÓN YPF

Principal Component Analysis

Componentes Principales → **Direcciones de máxima varianza**

El primer componente principal se ubica en la dirección donde los datos presentan varianza máxima.

El segundo componente principal se ubica en la segunda dirección en términos de varianza. Y así sucesivamente.

FUNDACIÓN YPF

PCA vs. SVD

Parametros y Caracteristicas	
PCA	**SVD**
Número de componentes	Rango r
Componentes principales	Vectores singulares por derecha
Autovalores	Valores singulares
Maximiza Varianza	Minimiza Distancia

FUNDACIÓN YPF



Descanso

Nos vemos en 10 minutos

FUNDACIÓN YPF

Sección Práctica

TRABAJAMOS EN SALAS

SVD

Trabajaremos con la Notebook 22

En los grupos establecidos, ejercitamos como se implementa el SVD

45 minutos de actividad



FUNDACIÓN YPF

Repasamos dudas

Trabajamos con la Notebook 22

Revisamos los conceptos y el código trabajados en la notebook 22



FUNDACIÓN YPF

Preparando la cuarta pre-entrega

En la clase 33 deberán realizar la cuarta pre-entrega
La misma incluirá los desafíos vistos, en relación a los modelos de aprendizaje no supervisado.

- Deberán desarrollar un modelo de clustering, desde el análisis exploratorio hasta la mejora
- Elegir algún algoritmo y aplicarlo a su proyecto.
- Será importante que hagan una revisión y tomen decisiones, para aplicar lo visto con un criterio que deberán explicitar.



Presentarán lo trabajado entregando el link a su Github en el foro del aula virtual

FUNDACIÓN YPF

¿Alguna consulta?

FUNDACIÓN YPF



¡Muchas Gracias!

En la próxima clase veremos:

CLASE PRÁCTICA Y DE REPASO