

Propuesta

Data Science

Programa Energia Digital

Fundación YPF - Jump Educación

Propuesta Versión 2.0

Planificación Data Science

Data Science

- **Cantidad de clases por semana:** 2 clases por semana de 3 hs cada una.
- **Cantidad horas total:** Data Science 3hs (32 clases - 4 meses)
- **Objetivos específicos de las clases:**
 - Aprender la teoría y las consideraciones técnicas necesarias para la construcción de modelos de Machine Learning
 - Aprender a solucionar problemas reales en diversas industrias de manera predictiva
 - Aprender a utilizar el lenguaje de programación Python para construir programas computacionales
 - Adquirir herramientas necesarias para construir modelos de Machine Learning a partir de datos en estado puro y desde cero
- **Contenidos mínimos:**
 - Python
 - Git
 - Análisis y predicción para la toma de decisión
 - Machine Learning: Algoritmos supervisados y no supervisados
- **Práctica:**

Las prácticas son en clase con ejercicios de aplicación.

Las participantes podrán realizar las prácticas en equipo o individualmente. Se hará foco en el trabajo en comunidad así como la búsqueda de información vinculante por parte de las participantes con el fin de incentivar el aprendizaje de manera autodidacta.

Las asistentes al programa pueden seleccionar el tema a trabajar durante todo el curso, se motiva la búsqueda de temas que brinden una solución a una problemática social así como el desarrollo productivo.

Al finalizar el curso, las participantes habrán aplicado lo aprendido en su propio proyecto.
- **Evaluación y Dinámicas de Trabajo:**

El curso promueve una evaluación formativa y procesual, distinguiendo claramente entre el trabajo diario en clase y la evaluación formal del proyecto:

 - ****Prácticas y Trabajos en Equipo en Clase**:** Actividades cotidianas y desafíos interactivos en salas de Zoom (de resolución grupal o individual) que permiten a las estudiantes aplicar la teoría en tiempo real, experimentar con código, colaborar en la resolución de problemas y recibir feedback continuo. No conllevan una calificación tradicional, sino que alimentan la nota conceptual.
 - ****Evaluación del Proyecto Final (Grupal, Máx. 3 Integrantes)**:** Desarrollo de un proyecto práctico incremental. Se evaluará a través de pre-entregas pautadas y una presentación oral en la última clase. El proyecto debe incorporar un análisis exploratorio riguroso, el ajuste de modelos de Machine Learning (supervisados y no supervisados), documentación técnica

detallada (con explicaciones y comentarios claros) y una sección de reflexión sobre sesgos, límites del modelo y uso ético de tecnologías de IA.

Descripción del curso

Este curso está orientado a que los participantes sean capaces de utilizar herramientas tecnológicas para trabajar con datos complejos provenientes de distintas fuentes, explorar espacios de información, modelar procesos y estructuras y apoyar la toma de decisiones. El programa inicia con conocimientos de Python orientados a su aplicación en Data Science y Machine Learning. Luego, se desarrollarán temas relacionados con la interpretación, manipulación y visualización de los datos. Finalmente, se profundizará en conceptos y aplicaciones de aprendizaje automático como algoritmos de clasificación y de regresión supervisados como así también algoritmos no supervisados.

Objetivos del curso

- Aprender fundamentos básicos de Python como así también buenas prácticas del lenguaje y entender su relevancia como herramienta para Data Science y Machine Learning
- Comprender la importancia del Análisis Exploratorio de Datos y realizar su implementación en diversos datasets
- Introducirse al mundo del aprendizaje automático
- Descubrir herramientas de Python para el desarrollo de modelos y el análisis de datos
- Comprender las etapas de entrenamiento y testeo de modelos
- Conocer características generales y fundamentos estadísticos de modelos de aprendizaje supervisado y no supervisado
- Implementar modelos de aprendizaje supervisado y no supervisado a problemas reales

Pre-requisitos

Para avanzar con la cursada, será necesario que las estudiantes hayan hecho cursos previos de Data Analytics: conozcan sobre tipos de análisis y visualizaciones, diferencias entre datos e información, bases de datos, SQL y estadística básica.

Contenidos y agenda

Módulo I - Introducción a Data Science

Cantidad clases: 1

Clase 1: ¿Qué es Data Science?

- Qué es Data Science
- Cuales son las habilidades de un Data Scientist
- Etapas de un proyecto de Data Science
- Librerías científicas de Python más usadas

- Jupyter Notebook y Anaconda, qué son, cómo instalarlos y alternativas modernas (VS Code y Google Colab).

Uso ético y productivo de copilotos de IA (asistentes de código) en el entorno de trabajo.

Módulo II: Introducción a Python

- ¿Qué es Python?
- Sintaxis de Python
- Dato, Variables y Operadores

Módulo II - Python para Data Science

Cantidad clases: 3

Clase 2:

Continuación Introducción a Python

- Listas
- Diccionarios
- Indexing

Conceptos Básicos de Git

- ¿Qué es Git?
- Importancia del control de versiones
- GitHub y GitLab
- Como crear un repositorio
- Comandos básicos para interactuar con Git

Uso de asistentes de código (LLMs) para depurar y comprender la lógica de programación en Python.

Clase 3:

Python Intermedio

- Condicional IF
- Bucle FOR
- Funciones y Métodos
- String Formatting

Introducción a Numpy

- ¿Por qué NumPy?
- Arrays y sus características

- Funciones matemáticas en Arrays

Introducción a la manipulación moderna de datos: de Pandas a la sintaxis rápida y eficiente de Polars.

Clase 4:

Primera parte Introducción a Pandas

- Crear un DataFrame
- Atributos y Funciones Básicas
- Seleccionar y Filtrar Columnas y Filas
- Operaciones y Manipulación de Dataframes
- Práctica - Numpy y Pandas

Pandas vs. Polars: comparación práctica de rendimiento en datasets y cuándo elegir cada una.

Módulo III - Análisis Exploratorio de Datos

Cantidad clases: 5

Clase 5: Introducción al Análisis Exploratorio de datos

- ¿Qué es el Análisis Exploratorio de datos?
- Importancia del Análisis Exploratorio de datos
- ¿Qué debo buscar en un Análisis Exploratorio?

Exploración de datos - Parte 1

- Descripción de datos
- Visualización de datos

Análisis Exploratorio local con DuckDB: consultas SQL rápidas directamente sobre archivos CSV y Parquet.

Clase 6: Exploración de datos - Parte 2

- Valores Faltantes
- Filtrado de Outliers

Explorando los datos - esta parte de la Clase 100% Practica

Identificación y manejo estadístico de outliers e imputación asistida por modelos de lenguaje.

Clase 7: Transformación de datos parte 1

- Conceptos Básicos de Feature Engineer
- Obtención de variables derivadas
- Encoder de variables
- Discretización de variables

Transformación de datos parte 2

- Re-escalado de variables

Feature Engineering moderno para datos estructurados y no estructurados (preprocesamiento conceptual de textos).

Clase 8: Transformación de datos parte 2

- Estandarización de variables
- Normalización de variables

Evaluación visual de distribuciones y escalamiento asistido.

Clase 9: Transformación de datos - _Clase 100% Práctica y retomar dudas o conceptos anteriores

Módulo IV - Fundamentos de Machine Learning

Cantidad clases: 2

Clase 10: ¿Qué es ML?

- Definición de Machine Learning
- Aprendizaje vs. Inteligencia
- Conceptos Fundamentales
- Componentes Principales

Diferencias entre Machine Learning tradicional, Deep Learning y modelos generativos basados en Transformers (LLMs).

Clase 11: Tipos de algoritmos

Introducción conceptual al procesamiento del lenguaje (NLP): de representaciones tradicionales (Bag of Words) a Embeddings.

Inicio de Modulo V: **Aprendizaje automático supervisado**

Módulo V - Aprendizaje automático supervisado

Cantidad clases: 7

Clase 12: Regresión y clasificación

- Diferencia entre regresión y clasificación

Algoritmos más comunes para regresión y clasificación - Parte 1

- Regresión Lineal
- Regresión Logística
- Árboles de Decisión

Interpretación de coeficientes de regresión y decisiones en árboles de clasificación.

Clase 13: Algoritmos más comunes para regresión y clasificación - Parte 2

- Random Forest
- k-Nearest Neighbors
- Support Vector Machine

Ajuste moderno de hiperparámetros: del clásico GridSearchCV a la optimización automatizada con Optuna.

Clase 14: Clase 100% Practica - Regresión y Clasificación

Clase 15:

- Evaluación y métricas

Métricas avanzadas para modelos predictivos y el reto de evaluar respuestas no estructuradas de modelos generativos.

- Overfitting y

Clase 16:

- Repaso anterior
- Validación Cruzada
- Práctica: Métricas y Overfitting

Clase 17: Clase 100% Practica

Retomar conceptos anteriores y repaso del módulo.

Explicabilidad de Modelos (XAI): introducción conceptual a SHAP y LIME para modelos de caja negra.

Clase 18: Clase 100% práctica (Regresión)

Retomar conceptos anteriores y repaso del módulo

Explicabilidad de Modelos (XAI): introducción conceptual a SHAP y LIME para modelos de caja negra.

Módulo VI - Aprendizaje automático no supervisado

Cantidad clases: 6

Clase 19: Tipos de aprendizaje no supervisado

Clustering: K-means

Aplicación práctica: Clustering de textos usando Embeddings vectoriales.

Clase 20: Repaso y práctica K-means

Clase 21: Clustering DBSCAN y repaso

Clase 22: Métricas para Clustering

Repaso e introducción a Single Value Decomposition

Búsqueda por similitud vectorial: distancia coseno y el rol de las bases de datos vectoriales (ChromaDB, Pinecone).

Clase 23:

Single Value Decomposition

Clase 24: Clase 100% Práctica - Aprendizaje No Supervisado

Espacio de repaso del módulo - dudas preguntas

Módulo VII - Introducción a redes neuronales y Deep Learning

Cantidad clases: 4

Clase 25: Introducción a las redes Neuronales y Keras

- Introducción a las redes Neuronales
- Descenso por gradiente
- Herramientas de Python para RN

Concepto de Perceptrón Simple

- Perceptrón Simple
- Función Sigmoidea

Clase 26: Concepto de Perceptrón Multicapa (MLP) y su entrenamiento (descenso por gradiente y retropropagación conceptual sin saturación matemática).

- Arquitecturas típicas de redes densas y funciones de pérdida.
- Conceptos de propagación hacia adelante y hacia atrás (Forward & Backpropagation) explicados de forma intuitiva.

Perceptrón Multicapa

- Perceptrón Multicapa

Clase 27: Introducción a la IA Generativa

- La arquitectura Transformer y la revolución de los modelos de lenguaje (LLMs)
- Acceso programático a LLMs a través de APIs (OpenAI, Hugging Face)
- Configuración de hiperparámetros de generación (temperatura, top_p, etc.)
- Repaso

Clase 28: Taller Práctico - Construcción de una aplicación de consulta básica (RAG) utilizando LangChain o LlamaIndex.

Integración de documentos locales y almacenamiento vectorial rápido en memoria.

Módulo VIII - Deployando un Modelo

Cantidad clases: 4

Clase 29: Del Notebook a Producción: empaquetamiento y modularización de código.

- Construcción de APIs web utilizando FastAPI para servir predicciones del modelo en tiempo real.
- Prueba local de la API y diseño de payloads (JSON).

Buenas prácticas de testing básico para APIs de modelos.

Monitoreo de Modelos en Producción

- Monitoreo de modelos y herramientas

Clase 30: Ciclo de vida de MLOps y Gobernanza

- Registro de experimentos y control de versiones de modelos utilizando MLflow.

Monitoreo básico en producción: detección y manejo de data drift y concept drift.

- Introducción conceptual a la contenerización utilizando Docker (¿por qué es clave para la reproducibilidad?).

Clase 31: Despliegue en la Nube y Portfolio

- Taller práctico: Despliegue de la API del modelo en la nube (Render o Hugging Face Spaces) y estructuración de un portfolio interactivo en GitHub.

Clase 32:

- Espacio de presentación de proyectos y cierre

Presentación final y debate sobre límites, sesgos y uso responsable de la IA.